体型感知的音乐驱动舞蹈动作风格化生成

李晨光[1)], 温玉辉[1)*], 景宇宸[1)], 汪意[1)], 张亚宇[1)], 周正忠[1)], 刘永进[2)], 景丽萍[1)]

[1)] (北京交通大学计算机科学与技术学院　北京　100044)
[2)] (清华大学计算机科学与技术系　北京　100084)
(yhwen1@bjtu.edu.cn)

摘　要: 高质量舞蹈动作自动生成在电影和动画制作等产业需求广泛. 然而已有方法生成的动作往往难以适应不同虚拟角色的骨骼比例和几何外形, 且无法对舞蹈动作风格进行灵活控制. 为解决上述问题, 提出体型感知的音乐驱动舞蹈动作风格化生成方法. 首先基于体型感知的运动重定向方法建立包含不同骨骼比例和几何外形的虚拟角色舞蹈动作数据集 DanceDB++; 此外, 提出体型感知的音乐驱动舞蹈动作生成扩散模型, 利用交叉注意力机制将音乐特征与虚拟角色体型参数融合作为扩散模型的控制条件, 并引入考虑骨骼比例的辅助损失项; 同时, 引入语义风格引导模块, 从文本或示例动作中提取风格表示并通过自适应实例归一化层将其注入扩散模型, 以实现对生成动作风格的控制. 在 DanceDB++上的定量实验结果表明, 所提方法在足部物理接触得分等评估指标上的表现优于对比的舞蹈动作生成方法; 在定性实验中, 展示了一系列文本描述或示例动作控制舞蹈动作风格的生成结果, 表明所提方法在生成舞蹈动作时能够实现有效的风格化引导. 文中提出的数据集和基于计图框架的模型代码将会开源.

关键词: 舞蹈生成; 扩散模型; 体型感知
中图法分类号: TP391.41　　**DOI:** 10.3724/SP.J.1089.2024-00492

最新录用

Shape-Aware Stylized Dance Motion Generation Driven by Music

Li Chenguang[1)], Wen Yuhui[1)*], Jing Yuchen[1)], Wang Yi[1)], Zhang Yayu[1)], Zhou Zhengzhong[1)], Liu Yongjin[2)], and Jing Liping[1)]

[1)] (*School of Computer Science and Technology, Beijing Jiaotong University, Beijing*　100044)
[2)] (*Department of Computer Science and Technology, Tsinghua University, Beijing*　100084)

Abstract: The demand for high-quality dance motion generation is widespread in the film and animation industries. However, existing methods fail to adapt to varying skeletal proportions and geometric shapes of different virtual characters, and lack the flexibility to control the dance style. To address these issues, we propose a method for shape-aware music-driven stylized dance motion generation. First, we propose DanceDB++, a dance motion dataset of virtual characters with diverse skeletal proportions and geometric shapes based on a motion retargeting method that considers the body shape of character. Furthermore, we propose a shape-aware, music-driven dance motion generation diffusion model, which leverages a cross-attention mechanism to fuse the music features and the body shape parameters as the condition for the diffusion model, and introduce auxiliary training objectives based on skeletal proportions. Additionally, we introduce a semantic style guidance module that extracts style

收稿日期: 2024-08-22; 修回日期: 2024-11-30. **基金项目**: 北京市科技计划项目(Z231100005923029); 北京交通大学人才基金(2023XKRC045). **李晨光**(2002—), 男, 硕士研究生, 主要研究方向为人体动作生成; **温玉辉**(1990—), 女, 博士, 副教授, 硕士生导师, CCF 会员, 论文通信作者, 主要研究方向为三维隐式建模、三维动作表示与生成; **景宇宸**(2000—), 男, 硕士研究生, 主要研究方向为三维动作表示与生成; **汪意**(2001—), 男, 硕士研究生, 主要研究方向为三维隐式建模; **张亚宇**(2000—), 男, 硕士研究生, 主要研究方向为三维动作表示与生成; **周正忠**(2000—), 男, 硕士研究生, 主要研究方向为三维隐式建模; **刘永进**(1977—), 男, 博士, 教授, 博士生导师, CCF 会员, 主要研究方向为计算机图形学; **景丽萍**(1978—), 女, 博士, 教授, 博士生导师, CCF 会员, 主要研究方向为机器学习.

representations from text or example motions and injects them into the diffusion model through adaptive instance normalization layers, enabling flexible control over the generated dance style. The quantitative experimental results on DanceDB++ indicate that the proposed method outperforms the compared methods in metrics like physical foot contact score. In qualitative experiments, a series of stylized dance motions controlled by text descriptions or example motions show that the proposed method can effectively achieve stylized guidance in dance motion generation. The dataset and code based on Jittor framework will be publicly released.

Key words: dance generation; diffusion model; body shape aware

舞蹈是世界上多种文化的重要组成部分，在社会联系和情感表达方面发挥着重要作用[1]. 舞蹈动作经常出现在电影或者动画作品中，在相关产业需求广泛. 然而，舞蹈编排与创作充满了复杂性和挑战性，既要匹配音乐节奏，又要创造富有艺术感的动作. 在传统的电影和动画制作行业中，通常采用舞谱系统[2]或动作捕捉技术[3-5]等烦琐且昂贵的方式进行舞蹈的编排和创作.

近年来，从视频中估计人体动作的技术[6-8]不断发展，有利于收集大量数据，使得借助深度学习等技术自动生成舞蹈动作成为一种有效的数字内容制作方式，极大地减轻了舞蹈编排和创作的负担和成本，这种方法在许多应用领域具有重要的价值. 例如，在电影和动画制作领域，能够为不同角色自动生成个性化的舞蹈动作；在虚拟现实研究领域，使互动角色能够根据用户指定的音乐舞蹈以提升用户交互体验；在神经科学研究领域[9]，舞蹈生成方法还可以用于深入探究音乐和运动之间的关系.

目前，基于生成对抗网络[10]、变分自编码器[11]和扩散模型[12-13]等的舞蹈生成方法能够生成较高质量的舞蹈动作，然而这些方法生成舞蹈动作时往往忽略了人体体型(包括人体骨骼比例和几何外形)的差异，并且缺乏对动作风格的引导. 因此，其生成的动作直接用于驱动虚拟角色时，会产生动作不合理或者穿模等瑕疵，需要额外的手工操作制作高质量动画，难以实现灵活的风格控制. 本文提出自动适应于不同体型虚拟角色的音乐驱动舞蹈动作风格化生成方法. 首先基于体型感知的运动重定向方法建立不同体型虚拟角色的舞蹈动作数据集，包含 18 个虚拟角色共 23 h 的舞蹈动作以及伴奏音乐. 现有的通过动作捕获技术得到的高质量舞蹈数据集较少，可主要归因为 2 个方面: (1) 动作捕获设备要求在专业场地采集动作，以及需要专业人员处理数据，操作步骤烦琐；(2) 专业舞蹈演员体型差异较小，难以直接捕获到体型差异较大采集对象的舞蹈动作. 针对以上问题，所提方法基于体型感知的运动重定向方法，采用残差结构的神经网络将舞蹈动作在不同骨骼比例和几何外形的虚拟角色之间进行重定向，收集不同体型的虚拟角色舞蹈动作数据. 进一步，提出体型感知的音乐驱动舞蹈动作生成扩散模型，利用交叉注意力机制将预训练生成模型提取的音乐特征与虚拟角色人体参数模型的体型参数融合作为扩散模型的控制条件. 为了训练扩散模型生成自动适应于不同体型虚拟角色的舞蹈动作，引入考虑骨骼比例的关节位置匹配损失和脚部接触一致性损失，作为训练扩散模型的辅助损失项. 通过考虑舞蹈演员的骨骼比例，能够更准确地模拟演员的身体结构和运动能力. 同时设计语义风格引导模块，采用预训练文本和动作编码器对引导条件进行编码，将用于引导动作风格的文本或示例动作统一到对比语言-图像预训练(contrastive language-image pretraining, CLIP)语义空间，进一步通过自适应实例归一化(adaptive instance normalization, AdaIN)层将其与扩散模型融合，实现动作生成中的风格控制. 综上所述，本文方法根据舞蹈演员独特的骨骼比例和身体几何外形生成舞蹈动作并对生成过程进行风格化引导，使得生成的舞蹈动作更加符合舞蹈演员的生理特征和运动学原理.

1 相关工作

对人体动作生成、音乐驱动舞蹈动作生成，以及运动重定向领域的研究背景和当前工作的局限性进行阐述.

1.1 人体动作生成

人体动作生成是计算机图形学和计算机视觉[14-16]、多媒体[17-18]、机器人[19-20]和人机交互[21-22]等领域中备受关注且具有挑战性的问题. 研究人员致力于研究生成自然、真实和多样化人体动作的方法，满足电影和动画制作等产业广泛的应用需

求.

随着深度学习的不断发展，基于各种输入条件的人体动作生成成为当前热门的研究领域. Guo 等[23]采用多层感知机架构，通过动作本身的部分内容控制动作生成；Cervantes 等[24]提出一种基于变分隐式神经表示的类别引导动作生成方式；Tevet 等[25]将 CLIP 模型[26]学习到的文本和图像共享的隐空间扩展到文本和动作领域，以摆脱数据限制，并允许在隐空间内进行动作编辑；随着扩散模型在图像和视频生成任务上取得了令人满意的表现[27-28]，其在条件引导动作生成领域也取得了良好的性能；Kim 等[29]将自由形式语言描述引入运动合成与编辑；Tevet 等[30]采用一种无分类扩散生成模型，适应于不同条件下的动作生成任务.

1.2 音乐驱动舞蹈动作生成

舞蹈生成任务的目标是根据输入的音乐序列生成相应的舞蹈动作序列. 早期的方法[31-33]遵循动作检索范式，生成的舞蹈缺乏真实性和人类创作舞蹈的复杂性. 随着深度学习的发展，研究人员提出一系列回归模型. Li 等[34]采用跨模态注意力机制，并以自回归的方式对未来运动帧进行预测；Tang 等[35]使用长短期记忆(long short-term memory, LSTM)自动编码器提取声学特征，并利用 LSTM 自编码器将其转换为运动特征；GDancer[36]中引入全局-局部运动表示，确保运动的局部一致性和全局一致性. 这些方法采用监督学习回归模型处理舞蹈动作生成问题. 然而，由于给定的音乐序列可以生成多种合理的舞蹈动作，因此回归模型无法充分解决这种一对多的映射关系.

近年来，随着生成式概率模型的迅速发展，其在舞蹈生成领域的运用受到广泛关注. 一系列基于生成对抗网络[10]、变分自编码器[11]的舞蹈生成方法，能够生成较高质量的舞蹈动作. 其中，基于生成对抗网络的方法[37-38]采用对抗性学习规范生成和真实的运动数据流形之间的距离；Bailando[39]使用矢量量化变分自编码器[40]对三维运动进行量化，然后利用基于演员-评论家算法[41]的生成式预训练 Transformer 模型从学习到的隐码中组成序列；最近，音乐生成可编辑舞蹈(editable dance generation from music, EDGE)[42]基于扩散模型构建，并将该任务定义为一个基于音乐条件的运动去噪问题. 然而，这些方法生成的舞蹈动作难以适应不同体型的虚拟角色，直接驱动虚拟角色可能出现动作不真实或穿模等瑕疵. 在舞蹈动作生成中，本文方法考虑舞蹈演员的不同体型并对其进行风格引导，能够生成自适应于不同体型虚拟角色的个性化舞蹈动作，直接驱动虚拟角色生成高质量动画.

1.3 运动重定向

运动重定向最初由 Gleicher[43]提出，将源运动的特征识别为运动学约束，并解决了时空优化问题；随后，研究者们提出许多基于优化的运动重定向方法，引入特定的约束条件，如动力学约束[44]、逆向运动学约束[45]、关节角约束[46]、欧几里得距离约束[47]和轨迹约束[48]. 近年来，基于深度学习的运动重定向研究蓬勃发展. Jang 等[49]使用结合深度卷积逆图形网络[50]和 U-Net[51]的深度自动编码器生成人体运动；Villegas 等[52]训练无监督运动重定向的神经运动学网络；Aberman 等[53]提出一种骨架感知网络，用于重定向具有不同拓扑结构的骨架之间的运动. 然而，这些方法忽略了角色的几何形状. Zhang 等[54]的方法能够在不同骨骼比例和几何外形的虚拟角色之间进行重定向. 本文基于以上运动重定向工作，在不同体型的虚拟角色之间进行舞蹈动作重定向，建立舞蹈动作数据集，研究体型感知的舞蹈动作生成扩散模型.

2 本文方法

本文通过运动重定向方法建立了一个包含不同体型演员的舞蹈动作数据集. 同时基于扩散模型，利用交叉注意力机制将预训练生成模型提取的音乐特征和舞蹈演员体型参数作为控制条件，并引入风格引导模块. 该方法生成的舞蹈动作具有较高的真实感和多样性，能够自适应于不同体型的虚拟角色，整体方法的框架如图 1 所示.

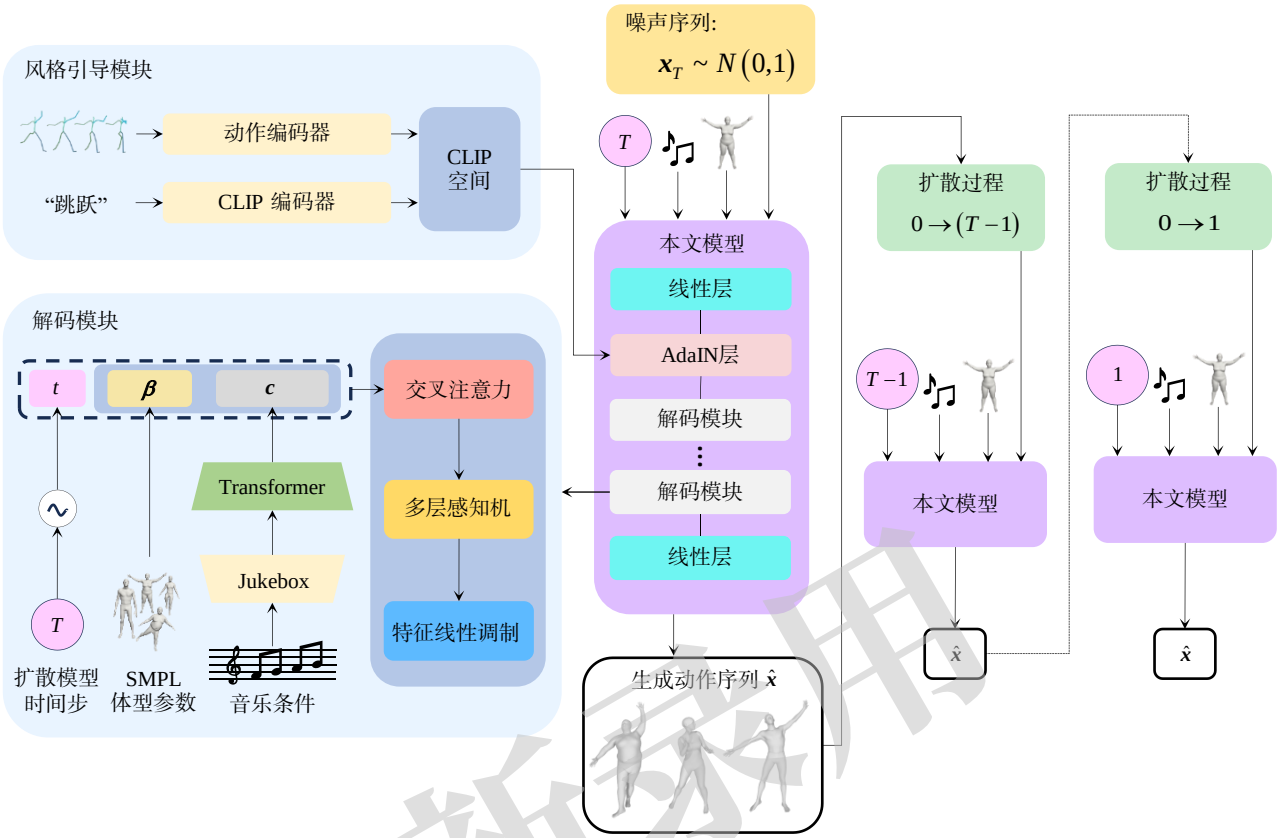

图 1 本文方法框架

本文方法生成的动作不仅与输入的音乐节奏匹配，而且能够符合编舞者期望的舞蹈风格，直接用于驱动目标虚拟角色，生成具有舞蹈动作真实感和多样性的虚拟角色动画，如图 2 所示.

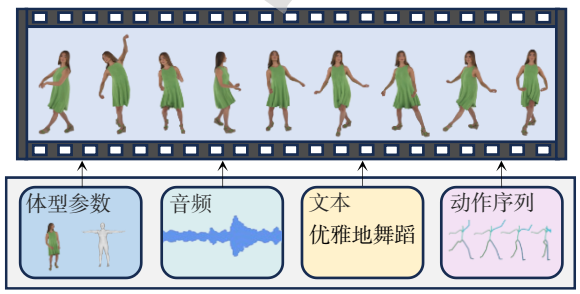

图 2 本文方法生成虚拟角色舞蹈动作示意图

2.1 人体体型及动作表示

在人体建模领域，蒙皮多人线性模型(skinned multi-person linear, SMPL)[55-57]作为一种三维参数化人体模型，在学术界得到了广泛的应用.

本文采用 SMPL 模型的体型参数 $\boldsymbol{\beta}$ 表示虚拟角色体型；24 个关节的旋转和根关节的位移表示舞蹈动作 $\boldsymbol{\delta} \in \mathbb{R}^{24\times6+3=147}$，其中，关节旋转采用 6 自由度[58]的表示形式；采用二值标签 $\boldsymbol{b} \in \{0,1\}^{2\times2=4}$ 表示足跟关节和足趾关节与地面的接触[42]. 则整体舞蹈动作序列表示形式为 $\boldsymbol{x} = \{\boldsymbol{\delta}, \boldsymbol{b}\} \in \mathbb{R}^{4+147=151}$.

2.2 运动重定向与数据增强

本文中，需要不同体型人物的动作序列作为训练数据. 现有的开源舞蹈动作数据集大部分只包含人体动作数据，仅有开源数据集 DanceDB[59]的舞蹈数据包含表演者的 SMPL 体型参数，但该数据集只包含 8 个表演者的舞蹈动作数据与开源音乐信息. 为获得更多不同体型的舞蹈动作序列，本文将 DanceDB 数据集中 8 个舞蹈演员，时长共计 4 686 s 的 50 段舞蹈动作重定向到 18 个不同体型的演员上(如图 3 所示)，提出目前最大的包含音乐和不同人体体型参数的三维舞蹈动作数据集 DanceDB++数据集，用于训练体型感知的舞蹈动作生成模型. DanceDB++数据集与现有舞蹈动作数据集的对比如表 1 所示.

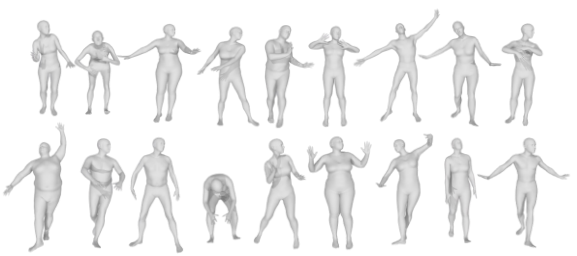

图 3 不同体型的人体模型

最新录用

表 1　舞蹈动作数据集比较

数据集	音乐	三维关节		体型参数	时长/s
		位置	旋转		
AIST++[34]	√	√	√	×	18 694
Dance with Melody[35]	√	√	×	×	5 640
GrooveNet[60]	√	√	×	×	1 380
DanceNet[61]	√	√	×	×	3 472
EA-MUD[62]	√	√	×	×	1 254
DanceDB[59] (音乐开源)	√	√	√	√	4 686
DanceDB++	√	√	√	√	84 357

在动作重定向的过程中，由于不同角色的骨骼长度比例和身体几何外形存在较大差异，因此直接将动作在虚拟角色间进行迁移会导致动作语义不一致和肢体穿模等问题[54]. 受到文献[54]的启发，本文采用预训练残差结构的神经网络，将舞蹈动作在不同骨骼比例和几何外形的角色之间进行重定向，如图 4 所示. 该网络包含骨骼比例感知模块和几何外形感知模块，采用平衡门控单元对模块间的权重进行调节.

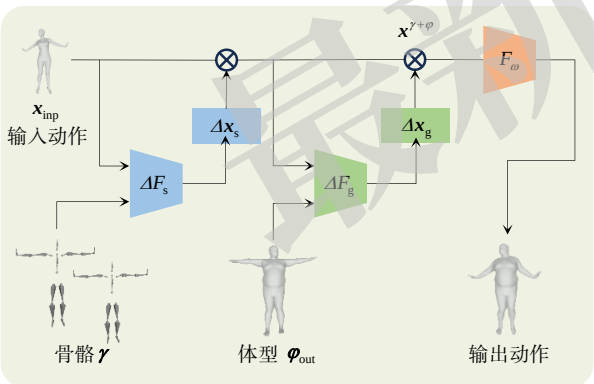

图 4　人体动作重定向残差网络

骨骼比例感知模块 ΔF_s 以 M 帧输入动作 $\boldsymbol{x}_{inp}$，以及静止姿势下源角色与目标角色的骨骼信息 $\boldsymbol{\gamma}_{inp}$ 和 $\boldsymbol{\gamma}_{out}$ 作为输入，输出面向骨骼比例的四元数修正 $\Delta\boldsymbol{x}_s \in \mathbb{R}^{M\times 4}$. 对 $\Delta\boldsymbol{x}_s$ 和 $\boldsymbol{x}_{inp}$ 应用汉密尔顿乘积后，得到保留输入运动语义的输出 $\boldsymbol{x}^{\gamma}$，公式为

$$\boldsymbol{x}^{\gamma} = \Delta\boldsymbol{x}_s \otimes \boldsymbol{x}_{inp} = \Delta F_s\left(\boldsymbol{\gamma}_{inp}, \boldsymbol{\gamma}_{out}, \boldsymbol{x}_{inp}; \theta_s\right) \otimes \boldsymbol{x}_{inp}.$$

其中，θ_s 表示 ΔF_s 的网络参数.

几何外形感知模块 ΔF_g 以 ΔF_s 输出的局部关节旋转 $\boldsymbol{x}^{\gamma}$ 和目标角色每个关节对应的身体部位包围盒的边长 $\boldsymbol{\varphi}_{out}$ 作为输入，输出面向几何外形的四元数修正量 $\Delta\boldsymbol{x}_g \in \mathbb{R}^{M\times 4}$，将其与 $\boldsymbol{x}^{\gamma}$ 应用汉密尔顿乘积后，得到输出 $\boldsymbol{x}^{\gamma+\varphi}$，公式为

$$\boldsymbol{x}^{\gamma+\varphi} = \Delta\boldsymbol{x}_g \otimes \boldsymbol{x}^{\gamma} = \Delta F_g\left(\boldsymbol{\varphi}_{out}, \boldsymbol{x}^{\gamma}; \theta_g\right) \otimes \boldsymbol{x}^{\gamma}.$$

其中，θ_g 表示 ΔF_g 的网络参数.

平衡门控单元 F_ω 通过在 $\boldsymbol{x}^{\gamma}$ 和 $\boldsymbol{x}^{\gamma+\varphi}$ 间进行线性插值，平衡修正量 $\Delta\boldsymbol{x}_s$ 和 $\Delta\boldsymbol{x}_g$ 对动作重定向的影响，公式为

$$\boldsymbol{x}_{out} = (1-\omega)\times \boldsymbol{x}^{\gamma} + \omega \times \boldsymbol{x}^{\gamma+\varphi}.$$

其中，ω 表示平衡权重，取值范围为 $\omega \in [0,1]$.

该网络基于 Mixamo 数据集[63]并采用两阶段策略进行训练. 其中第一阶段以 0.001 学习率训练骨骼比例感知模块，第二阶段以 0.000 1 学习率训练几何外形感知模块，并以 0.3 的概率将平衡权重 ω 设置为 1，以确保几何外形感知模块的稳定学习过程. 重定向后的动作保留了输入动作的语义信息，并消除了几何外形上的肢体穿模问题. 通过动作重定向方法，能够得到不同体型角色的高质量舞蹈动作.

2.3　条件控制舞蹈动作生成

本文方法基于扩散模型，从纯噪声中逐步学习去噪生成舞蹈动作(如图 1 所示). 扩散模型包含前向过程(扩散过程) q 和逆向过程(去噪过程) p_θ. 此外，由于舞蹈动作生成通常包含条件信号，因此生成的动作不仅应该本身合理，而且应与条件信号协调一致. 下面阐述条件控制的舞蹈动作生成，包含音频控制条件和 SMPL 体型参数控制条件.

2.3.1　扩散过程

扩散过程定义为马尔可夫噪声过程[12]. 本文采用符号 $\boldsymbol{x}$ 表示动作序列，$\boldsymbol{x}$ 与观测数据 $\boldsymbol{x}_0 \sim q(\boldsymbol{x}_0)$ 同维，$q(\boldsymbol{x}_0)$ 表示真实数据的分布. 前向噪声过程的定义为

$$q(\boldsymbol{x}_t|\boldsymbol{x}_0) \sim N\left(\sqrt{\bar{\alpha}_t}\boldsymbol{x}_0, (1-\bar{\alpha}_t)\boldsymbol{I}\right).$$

其中，$\boldsymbol{x}_t$ 表示时间步 t 时刻的动作；$\bar{\alpha}_t \in (0,1)$ 表示单调递减时间表的常数，当 $\bar{\alpha}_t$ 趋于 0 时，总时间步 T 时刻的动作 $\boldsymbol{x}_T$ 可近似为 $\boldsymbol{x}_T \sim N(0,\boldsymbol{I})$.

2.3.2　去噪过程

p_θ 采用神经网络学习参数 θ，该过程同样符合高斯分布，基于 $\boldsymbol{x}_t$ 学习期望 $\boldsymbol{\mu}_\theta$ 和协方差 $\boldsymbol{\Sigma}_\theta$；然后通过 $p_\theta(\boldsymbol{x}_{t-1}|\boldsymbol{x}_t) = N\left(\boldsymbol{x}_{t-1}; \boldsymbol{\mu}_\theta(\boldsymbol{x}_t,t), \boldsymbol{\Sigma}_\theta(\boldsymbol{x}_t,t)\right)$ 逐步逆向推理 $\boldsymbol{x}_{t-1}$ 得到 $\boldsymbol{x}_0$.

本文以舞蹈音乐 $\boldsymbol{c}$ 和演员体型 $\boldsymbol{\beta}$ 作为 p_θ 的控制条件，通过扩散模型的逆向过程对全部 t 时刻下的 $\hat{\boldsymbol{x}}_\theta(\boldsymbol{x}_t, t, \boldsymbol{c}, \boldsymbol{\beta}) \approx \boldsymbol{x}_0$ 进行估计，其中，$\hat{\boldsymbol{x}}_\theta$ 表示模型估计量. 通过最小化真实样本与去噪结果间的距

离，对神经网络参数 θ 进行优化，公式为

$$L_{\mathrm{d}}=E_{\boldsymbol{x},t}\left[\left\|\boldsymbol{x}-\hat{\boldsymbol{x}}_{\theta}\left(\boldsymbol{x}_{t},t,\boldsymbol{c},\boldsymbol{\beta}\right)\right\|_{2}^{2}\right].$$

2.3.3 音频控制条件

音乐与舞蹈动作间存在多对多映射关系，丰富的节奏和音量强弱等音乐信息能够激发出不同的舞蹈动作. 近年来，音乐特征提取相关研究[64-65]表明，Jukebox 模型[66]在音频预测和生成任务上取得了很好的效果. Jukebox 是在 120 万首音乐上进行训练的大型音乐生成模型，能够为捕捉和表达音乐信息提供强有力的特征表示. 因此，本文参考文献[42]的方法，基于 Jukebox 提取的音乐特征对扩散模型的去噪过程进行控制.

2.3.4 体型控制条件

已有工作[34-39,42]主要关注音乐驱动舞蹈动作生成的建模方法，忽略了表演者的体型变化，生成的舞蹈动作直接用于驱动 SMPL 等参数化人体模型时，导致出现肢体穿模等瑕疵，影响真实感.

本文采用 16 维的 SMPL 体型参数 $\boldsymbol{\beta}$ 作为输入条件，用于控制扩散模型对噪声信号的去除过程. 参考文献[42]，将 SMPL 人体模型的体型参数与音乐特征在特征维度拼接后，利用交叉注意力机制与扩散模型相结合，以生成更加真实且符合舞蹈演员体型和风格的舞蹈动作.

2.3.5 去噪解码模块

本文采用 Transformer 解码模块结构，根据 Saharia 等[28]的方法使用交叉注意力机制对控制条件进行融合，包括音乐条件 $\boldsymbol{c}$ 、体型参数 $\boldsymbol{\beta}$ 和扩散模型时间步 t；然后通过多层感知机和特征级线性调制[67]进行处理(如图 1 所示)，使模型更好地适应输入数据的特征分布和上下文信息，提高生成动作的质量.

2.4 语义引导舞蹈动作风格化

舞蹈风格在舞蹈形式、情感表达等方面具有较高的辨识度，呈现出不同的艺术特色，恰当的风格化引导可以让动作更加富有魅力和感染力. 已有的方法[34,39,42]在生成舞蹈动作时缺乏对于舞蹈风格的引导，或者基于有限预定义标签引导动作生成[14,68]，无法灵活、准确地表达编舞者的创作意图. 本文通过设计风格引导模块，将示例动作或文本描述引导条件的 CLIP 语义编码注入舞蹈动作生成的扩散过程，实现动作生成的风格化控制.

特定动作序列能够提供形象的风格描述. 本文采用预训练的 MotionCLIP 编码器[25]对动作片段进行编码，提供人体动作生成的风格化引导. MotionCLIP 编码器以特定动作序列作为输入，通过 Transformer 架构将其编码为 CLIP 空间下包含该序列动作风格的隐式特征向量；然后通过多层感知机网络的映射将其转换为 AdaIN 层的参数，并修改 AdaIN 层每个通道的均值和方差，实现特定动作序列对动作生成风格化过程的控制.

文本引导动作风格化方法可以基于不同的文本描述进行生成，能够提供灵活的动作风格描述方式. 由于 MotionCLIP 编码器将动作片段投影到 CLIP 语义空间，因此本文利用预训练的 CLIP 编码器将期望动作的文本描述编码为隐式特征向量，即将动作的文本描述映射到 CLIP 空间；之后通过学习多层感知机网络，将文本描述的隐式特征编码映射为 AdaIN 层参数，实现动作生成过程的风格化控制.

2.5 训练损失函数

当前，辅助损失在动作生成领域得到了广泛应用，在缺乏真实模拟数据的情况下，辅助损失的引入[13,69-70]可以更好地提升动作生成的物理真实性. 在扩散模型的动作拟合损失 L_{d} 的基础上，参考文献[30]的方法引入辅助损失，分别对关节位置匹配损失 L_{joint} 、关节速度匹配损失 L_{vel} 和脚部接触一致性损失 L_{contact} 这 3 个方面的物理真实性进行拟合，公式为

$$L_{\mathrm{joint}}=\frac{1}{M}\sum_{i=1}^{M}\left\|K\left(\boldsymbol{x}^{(i)},\boldsymbol{\beta}\right)-K\left(\hat{\boldsymbol{x}}^{(i)},\boldsymbol{\beta}\right)\right\|_{2}^{2},$$

$$L_{\mathrm{vel}}=\frac{1}{M-1}\sum_{i=1}^{M-1}\left\|\left(\boldsymbol{x}^{(i+1)}-\boldsymbol{x}^{(i)}\right)-\left(\hat{\boldsymbol{x}}^{(i+1)}-\hat{\boldsymbol{x}}^{(i)}\right)\right\|_{2}^{2},$$

$$L_{\mathrm{contact}}=\frac{1}{M-1}\sum_{i=1}^{M-1}\left\|\left(K_{\mathrm{foot}}\left(\hat{\boldsymbol{x}}^{(i+1)},\boldsymbol{\beta}\right)-K_{\mathrm{foot}}\left(\hat{\boldsymbol{x}}^{(i)},\boldsymbol{\beta}\right)\right)\times\hat{\boldsymbol{b}}^{(i)}\right\|_{2}^{2}.$$

其中，$K(\cdot)$ 表示正向运动函数，用于将关节的旋转信息转换为关节的位置信息；$K_{\mathrm{foot}}(\cdot)$ 表示通过正向运动函数获得的脚部关节位置信息. 由于 L_{contact} 中仅涉及脚部关节的运算，因此 $\hat{\boldsymbol{b}}^{(i)}$ 表示模型对每帧 i 中的脚部接触的二值预测值.

本文将 SMPL 模型的体型参数 $\boldsymbol{\beta}$ 加入关节位置信息的计算中，使得关节位置的计算更准确,能够实现对人体形态更为精确的控制，以适应不同应用场景的需求.

本文对 L_{d} 与辅助损失进行加权求和，作为模型的整体训练损失，公式为

最新录用

$$L = L_{\mathrm{d}} + \lambda_{\mathrm{joint}} L_{\mathrm{joint}} + \lambda_{\mathrm{vel}} L_{\mathrm{vel}} + \lambda_{\mathrm{contact}} L_{\mathrm{contact}} .$$

其中，λ_{joint}，λ_{vel} 和 $\lambda_{\mathrm{contact}}$ 分别表示辅助损失项 L_{joint}，L_{vel} 和 L_{contact} 的权重. 使用 L 对模型参数进行优化，使生成的舞蹈动作更接近于真值.

3　实验结果与分析

3.1　数据集与模型训练

在 DanceDB++数据集上，对 18 位舞蹈演员中的每位舞蹈演员随机选取 4 段动作序列作为训练集，参考文献[42]对动作序列和对应的音频进行切片处理，每个序列切片长为 5 s，并采用同一划分比例，将每段动作的后 4 个切片作为测试集.

本文模型共包含 51M 参数量，批量大小设置为 128，使用 8 卡 NVIDIA RTX 3090 训练 15 h.

3.2　定量实验

将本文方法与 EDGE[42], Bailando[39]和 FACT[34]方法进行对比，从以下 3 个方面对生成的舞蹈动作进行评估: (1) 物理合理性; (2) 动作与音乐的匹配程度; (3) 舞蹈动作的多样性，结果如表 2 所示.

表 2　4 种方法对生成的舞蹈动作评估对比

方法	PFC↓	BAS↑	$\mathrm{Dist_k}$→	$\mathrm{Dist_g}$→
本文	**1.490**	**0.165**	**10.650**	**7.525**
EDGE[42]	1.509	0.164	10.712	7.593
Bailando[39]	2.140	0.161	10.480	7.505
FACT[34]	2.221	0.127	11.146	7.472
真值	1.361	0.180	10.657	7.542

注. 粗体表示最优值

3.2.1　物理合理性

为了确保生成的舞蹈动作在真实场景中的可应用性，需要满足一定的物理合理性要求. 在人体动作生成任务中，通常采用对脚步滑动的评估来衡量生成动作的物理合理性. 舞蹈动作因其本身的艺术性要求，脚步滑动十分常见，而且是舞蹈编排与创作的重要组成部分，因此本文采用足部物理接触得分(physical foot contact score, PFC)对生成的舞蹈动作的物理合理性进行评估[42]. 从表 2 可以看出，本文方法生成的动作 PFC 超越对比领先方法(state-of-the-art, SOTA). 表明该方法在舞蹈动作生成扩散模型中引入人体体型参数作为控制条件，并且引入考虑人体骨骼比例的 L_{joint} 和 L_{contact} 作为辅助损失项训练扩散模型，有利于提升舞蹈动作的脚部物理接触合理性.

3.2.2　动作与音乐的匹配程度

采用节拍对齐得分(beat alignment score, BAS)来衡量舞蹈动作与音乐节拍的匹配程度[39]. 从表 2 可以看出，与对比方法相比，本文方法的 BAS 指标最优，能够更准确地捕捉舞蹈动作与音乐节拍间的关联关系. 表明该方法在舞蹈动作生成中，引入人体体型参数与音乐特征融合作为舞蹈动作生成的控制条件，并考虑虚拟角色的骨骼比例和身体几何外形，能够更好地学习舞蹈动作数据分布.

3.2.3　舞蹈动作的多样性

参考文献[34,39]对动作多样性指标进行计算，衡量生成的舞蹈动作在运动学($\mathrm{Dist_k}$)和几何($\mathrm{Dist_g}$)特征空间中的特征分布. 由于舞蹈动作生成的目标是生成与真实分布相近的舞蹈动作，因此动作多样性应与真实分布相匹配，而非最大化其绝对值[34,39]. 从表 2 可以看出，所提方法在多样性方面更接近真实数据分布，进一步验证该方法引入人体体型参数作为扩散模型控制条件并改进 L_{joint} 和 L_{contact}，使得生成的舞蹈动作具有更高的逼真度.

3.3　定性实验

基于文献[71]方法对 ActorsHQ 数据集[72]中的人体模型进行驱动，将本文方法生成的动作与对比 SOTA 方法 EDGE[42]生成的动作进行可视化，结果如图 5 所示. 可以看出，EDGE 方法的生成结果在部分动作下会发生穿模现象；而本文方法在考虑虚拟角色的体型对于动作生成的影响，并将 SMPL 模型的体型参数作为控制条件加入扩散模型后，生成的舞蹈动作能够更好地适应 ActorsHQ 数据集中不同体型的虚拟角色，有效地消除穿模现象，如图 6 所示. 表明该方法通过引入演员的体型参数作为控制条件，生成的舞蹈动作能够更准确地反映不同体型演员的特点，为不同体型差异的舞蹈演员提供更具适应性的舞蹈动作.

最新录用

图 5　SOTA 方法 EDGE[42]生成的动作发生穿模现象

图 6　本文方法生成的动作

最新录用

值得注意的是, ActorsHQ 数据集中的 SMPL 人体模型体型参数并未出现在训练集中，证明了本文方法具有较好的泛化性. 同时，本文方法生成的舞蹈动作具有多样性，如图 7 所示.

图 7　本文方法生成动作的多样性可视化

对于语义风格引导模块，基于 2 种不同类型的风格提示对动作的生成结果进行定性实验，包括文本描述动作风格和动作样例描述动作风格，结果如图 8 和图 9 所示. 可以看出，本文方法能够根据输入的文本描述或预先定义的动作语义信息引导模型生成符合特定风格含义的动作序列. 如图 8 所示，在文本动作风格引导动作生成任务中，对于用户指定的动作风格，本文方法能够根据相应的引导文本生成具有合理风格的人体动作. 例如，当希望生成结果为“芭蕾舞”风格时，文本提示为“双手张开并且膝盖弯曲”，虚拟角色能够表现出文本描述的优雅的舞蹈动作；当希望生成结果为“拉丁舞”风格时，文本提示为“侧步移动并且胯部扭动”，舞蹈动作包含侧步和扭胯，动作样式符合拉丁舞风格；当希望生成结果为“爵士舞”和“摩登舞”时，文本提示分别为“身体转动并且腿部摆动”和“双手举起并且迈步移动”，虚拟角色的动作能够与风格描述一致. 进一步，采用明确的文本动作描述对动作生成风格进行引导时，得到的动作生成结果能够准确地表达文本描述中包含的风格形式. 例如，文本描述为“举手”时，生成的动作能够在运动过程中保持双手的高举；文本描述为“旋转”时，生成的动作序列能够跟随音乐节奏进行旋转舞蹈.

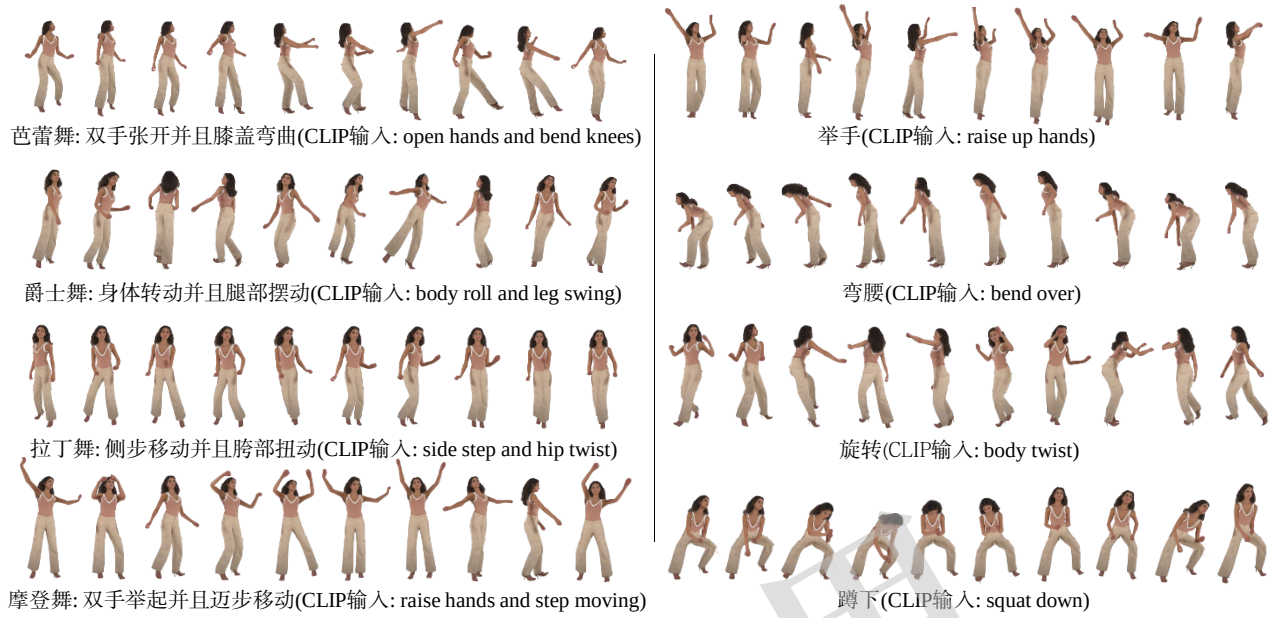

a. 抽象动作风格　　b. 明确动作描述

图 8　抽象动作风格与明确动作描述引导舞蹈动作生成

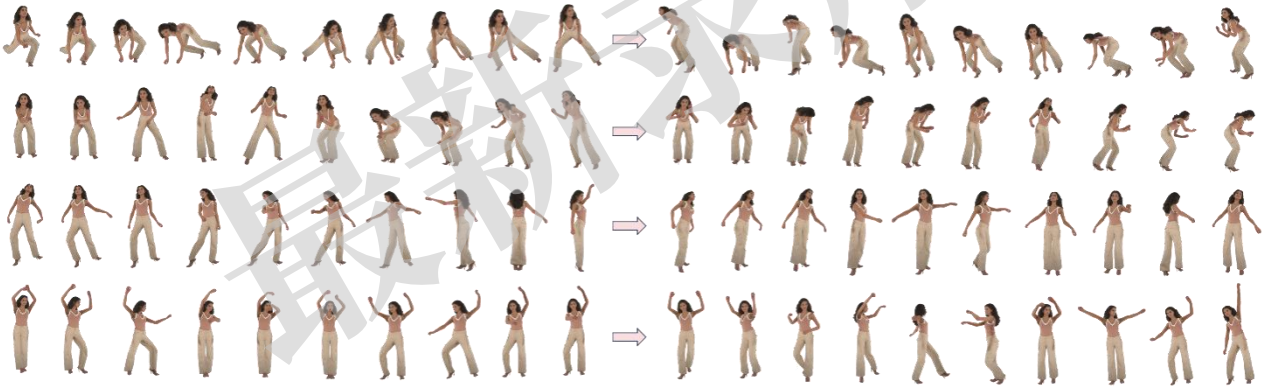

a. 动作片段　　b. 舞蹈动作生成

图 9　动作片段提取风格引导舞蹈动作生成

如图 9 所示，本文采用动作样例对生成舞蹈动作的风格进行引导，能够有效地提取动作片段中隐含的风格信息并将其融入到扩散模型中，对生成舞蹈动作的风格进行有效的引导．值得注意的是，来自训练数据集以外的风格类别的动作样例，能够有效地用于控制生成的舞蹈动作，说明本文方法具有良好的泛化性．本文方法通过交叉注意力机制，在扩散模型中引入 CLIP 特征的强大语义表示能力，在对身体部位进行风格控制的同时能够保持各个身体部位动作的自然协调，使得生成的动作更具表现力和逼真度．

对长文本引导动作生成进行实验，结果如图 10 所示．可以看出，由于 CLIP 模型长文本能力的缺失[73]，本文提出的语义风格引导模块难以接收长序列的动作文本描述，造成创作者的需求无法精确表达．例如，输入长文本“抬起手臂并在头顶交叉．双脚快速交替踏步，加速至跳跃动作．使身体的旋转与手臂的摆动同步．在空中完成转身，身体沿着弧形轨迹移动.”时，生成的动作虽然能够满足“抬起手臂”的需求，但未能捕捉到“手臂交叉”“旋转”等动作描述，如图 10a 所示；输入长文本“突然下蹲，膝盖微微弯曲，左腿用力蹬地使身体跃入空中．右腿按弧线挥动，同时双臂从腰部甩出，身体旋转一圈，头部自然转动.”时，虚拟角色虽然能够做出“下蹲”动作，但无法进一步满足“跃入空中”“旋转”的动作需求，如图 10b 所示．

最新录用

a. 未实现“手臂交叉”等动作

b. 未实现“跃入空中”等动作

图 10 长文本引导动作生成

3.4 用户测评

本文对生成舞蹈动作的动作真实感和节奏匹配性进行测评，并计算平均得分以进行评估. 在动作真实感测评中，测评者需要判断生成的舞蹈运动感是否与真实的人类舞蹈运动相似. 在节奏匹配性测评中，测评者对生成的舞蹈运动与舞蹈音乐的同步性进行测评，以判断生成的舞蹈是否与音频相匹配.

参考文献[68,74]从测试集中随机选取 10 段测试音频和相应的动作序列进行用户测评. 用户测评实验共有 20 位测评者参与，测评者的年龄在 20 至 30 岁之间. 每段测试音频长为 5 s，每个测评页包含 5 种方法的生成结果，分别为真值、本文方法、EDGE[42]、Bailando[39]和 FACT[34]. 每位测评者需要对 10 个测评页共 50 个视频进行测评，对于每个视频，测评者需要对测评问题进行回答. 对于动作真实感，测评者需要回答的问题为“你对舞蹈动作的动作真实感满意吗?”. 对于节奏匹配性，测评者需要回答的问题为“你对舞蹈动作的节奏匹配性满意吗?”. 测评者在 1 到 5 分的范围内以 1 分为间隔进行评分，对应的满意度分别为“非常不满意”“不满意”“一般”“满意”“非常满意”. 本文方法与其他方法的测评结果对比如表 3 所示. 根据测评者的反馈，本文方法生成的舞蹈动作具有更好的动作真实感和节奏匹配性.

表 3 动作真实感与节奏匹配性用户测评

方法	动作真实感	节奏匹配性
本文	**$4.085^{\pm 0.835}$**	**$3.980^{\pm 0.974}$**
EDGE[42]	$3.795^{\pm 0.868}$	$3.755^{\pm 0.908}$
Bailando[39]	$3.490^{\pm 0.938}$	$3.475^{\pm 1.005}$
FACT[34]	$3.550^{\pm 0.921}$	$3.070^{\pm 1.093}$
真值	$4.225^{\pm 0.943}$	$4.198^{\pm 1.022}$

注. 粗体表示最优值.

3.5 消融实验

通过消融实验，探究体型参数和辅助损失对动作生成性能的影响，结果如表 4 所示. 可以看出，将 SMPL 模型的体型参数融入舞蹈动作生成的控制条件，并将扩散模型动作拟合损失与辅助损失进行加权求和作为整体训练损失，对于生成舞蹈动作的脚部物理接触合理性和动作多样性有提升效果，且更接近于舞蹈动作数据的真实分布.

表 4 体型参数和辅助损失对动作生成性能的影响

方法	PFC↓	$\mathrm{Dist_k}$→	$\mathrm{Dist_g}$→
本文	**1.490**	**10.650**	**7.525**
无体型参数	1.492	10.571	7.518
无辅助损失	4.179	10.773	7.560
真值	1.361	10.657	7.542

注. 粗体表示最优值.

进一步，在 DanceDB++数据集上，采用体型特征明显的 10 位角色对模型中体型参数对舞蹈动作生成性能的影响进行实验，结果如表 5 所示. 可以看出，对于体型特征明显的舞蹈演员，将 SMPL 模型的体型参数融入舞蹈动作生成的控制条件中，对于生成舞蹈动作的脚部物理接触合理性和动作多样性有明显的提升效果.

表 5 特征明显的体型参数对动作生成性能的影响

方法	PFC↓	$\mathrm{Dist_k}$→	$\mathrm{Dist_g}$→
本文	**1.380**	**10.683**	**7.577**
无体型参数	1.547	10.666	7.545
真值	1.287	10.792	7.596

注. 粗体表示最优值.

4 结 语

本文提出一种基于扩散模型的音乐驱动舞蹈动作风格化生成方法. 该方法生成的舞蹈动作与音乐节奏匹配，并且可通过风格化引导生成多样化的舞蹈动作，能够直接用于驱动目标虚拟角色，无需额外后处理. 实验结果表明，本文方法生成的舞蹈动作在脚部物理接触合理性、音乐匹配性和多样性等方面均超越对比的舞蹈动作生成方法.

尽管本文方法在舞蹈动作生成方面取得了一定的进展，但仍存在一些局限性：本文提出的数据集规模相较于现有工作已有明显提升，但其中包含人体体型及舞蹈动作种类的多样性有限；尽管引入 CLIP 模型能够实现来自训练数据集以外的风格化舞蹈动作生成，但当前方法在捕捉和传达舞蹈的情感特征上仍有不足. 未来将进一步扩充舞蹈动作数据集规模，研究舞蹈的情感特征表示方式，并将其有效地融入生成模型中，实现具有情感表达的舞蹈动作生成.

最新录用

参考文献(References):

[1] LaMothe K. The dancing species: how moving together in time helps make us human[J]. Aeon, 2019, 1(1): 1-2.

[2] Davies E. Beyond dance: Laban's legacy of movement analysis[M]. London: Routledge, 2007

[3] Martinez J, Hossain R, Romero J, *et al*. A simple yet effective baseline for 3d human pose estimation[C] //Proceedings of the IEEE International Conference on Computer Vision. Los Alamitos: IEEE Computer Society Press, 2017: 2659-2668

[4] Mehta D, Sridhar S, Sotnychenko O, *et al*. VNect: real-time 3D human pose estimation with a single RGB camera[J]. ACM TRANSACTIONS on Graphics, 2017, 36(4): Article No.4

[5] Pavllo D, Feichtenhofer C, Grangier D, *et al*. 3D human pose estimation in video with temporal convolutions and semi-supervised training[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2019: 7745-7754

[6] Menolotto M, Komaris D S, Tedesco S, *et al*. Motion capture technology in industrial applications: a systematic review[J]. Sensors, 2020, 20(19): Article No.5687

[7] Desmarais Y, Mottet D, Slangen P, *et al*. A review of 3D human pose estimation algorithms for markerless motion capture[J]. Computer Vision and Image Understanding, 2021, 212: Article No.103275

[8] Mathis A, Schneider S, Lauer J, *et al*. A primer on motion capture with deep learning: principles, pitfalls, and perspectives[J]. Neuron, 2020, 108(1): 44-65

[9] Brown S, Parsons L M. The neuroscience of dance[J]. Scientific American, 2008, 299(1): 78-83

[10] Goodfellow I, Pouget-Abadie J, Mirza M, *et al*. Generative adversarial networks[J]. Communications of the ACM, 2020, 63(11): 139-144

[11] Kingma D P, Welling M. An introduction to variational autoencoders[J]. Foundations and Trends® in Machine Learning, 2019, 12(4): 307-392

[12] Ho J, Jain A, Abbeel P. Denoising diffusion probabilistic models[C] //Proceedings of the 34th International Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2020: Article No.574

[13] Sohl-Dickstein J, Weiss E A, Maheswaranathan N, *et al*. Deep unsupervised learning using nonequilibrium thermodynamics[C] //Proceedings of the 32nd International Conference on International Conference on Machine Learning. Cambridge: JMLR.org, 2015: 2256-2265

[14] Kim J, Oh H, Kim S, *et al*. A brand new dance partner: music-conditioned pluralistic dancing controlled by multiple dance genres[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2022: 3480-3490

[15] Alexanderson S, Nagy R, Beskow J, *et al*. Listen, denoise, action! Audio-driven motion synthesis with diffusion models[J]. ACM Transactions on Graphics, 2023, 42(4): Article No.44

[16] Ao T, Zhang Z Y, Liu L B. GestureDiffuCLIP: gesture diffusion model with CLIP latents[J]. ACM Transactions on Graphics, 2023, 42(4): Article No.42

[17] Guo C, Zuo X X, Wang S, *et al*. Action2Motion: conditioned generation of 3D human motions[C] //Proceedings of the 28th ACM International Conference on Multimedia. New York: ACM Press, 2020: 2021-2029

[18] Gao J B, Pu J F, Zhang H L, *et al*. PC-Dance: posture-controllable music-driven dance synthesis[C] //Proceedings of the 30th ACM International Conference on Multimedia. New York: ACM Press, 2022: 1261-1269

[19] Nishimura Y, Nakamura Y, Ishiguro H. Long-term motion generation for interactive humanoid robots using GAN with convolutional network[C] //Proceedings of the ACM/IEEE International Conference on Human-Robot Interaction. New York: ACM Press, 2020: 375-377

[20] Gulletta G, Erlhagen W, Bicho E. Human-like arm motion generation: a review[J]. Robotics, 2020, 9(4): Article No.102

[21] Kucherenko T, Hasegawa D, Henter G E, *et al*. Analyzing input and output representations for speech-driven gesture generation[C] //Proceedings of the 19th ACM International Conference on Intelligent Virtual Agents. New York: ACM Press, 2019: 97-104

[22] Yin T R, Hoyet L, Christie M, *et al*. The one-man-crowd: single user generation of crowd motions using virtual reality[J]. IEEE Transactions on Visualization and Computer Graphics, 2022, 28(5): 2245-2255

[23] Guo W, Du Y M, Shen X, *et al*. Back to MLP: a simple baseline for human motion prediction[C] //Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision. Los Alamitos: IEEE Computer Society Press, 2023: 4798-4808

[24] Cervantes P, Sekikawa Y, Sato I, *et al*. Implicit neural representations for variable length human motion generation[C] //Proceedings of the 17th European Conference on Computer Vision. Heidelberg: Springer, 2022: 356-372

[25] Tevet G, Gordon B, Hertz A, *et al*. MotionCLIP: exposing human motion generation to clip space[C] //Proceedings of the 17th European Conference on Computer Vision. Heidelberg: Springer, 2022: 358-374

[26] Radford A, Kim J W, Hallacy C, *et al*. Learning transferable visual models from natural language supervision[C] //Proceedings of the 38th International Conference on Machine Learning. New York: PMLR, 2021: 8748-8763

[27] Ho J, Chan W, Saharia C, *et al*. Imagen video: high definition video generation with diffusion models[OL]. [2024-08-22]. https://arxiv.org/abs/2210.02303

[28] Saharia C, Chan W, Saxena S, *et al*. Photorealistic text-to-image diffusion models with deep language understanding[C] //Proceedings of the 36th Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2022: 36479-36494

[29] Kim J, Kim J, Choi S. FLAME: free-form language-based motion synthesis & editing[C] //Proceedings of the 37th AAAI Conference on Artificial Intelligence. Palo Alto: AAAI Press, 2022: Article No.927

[30] Tevet G, Raab S, Gordon B, *et al*. Human motion diffusion model[OL]. [2024-08-22]. https://arxiv.org/pdf/2209.14916

[31] Fan R K, Xu S H, Geng W D. Example-based automatic music-driven conventional dance motion synthesis[J]. IEEE Transactions on Visualization and Computer Graphics, 2012, 18(3): 501-515

[32] Lee M, Lee K, Park J. Music similarity-based approach to generating dance motion sequence[J]. Multimedia Tools and Applications, 2013, 62(3): 895-912

[33] Ofli F, Erzin E, Yemez Y, *et al*. Learn2Dance: learning statistical music-to-dance mappings for choreography synthesis[J]. IEEE Transactions on Multimedia, 2012, 14(3): 747-759

最新录用

[34] Li R L, Yang S, Ross D A, *et al*. AI choreographer: Music conditioned 3D dance generation with AIST++[C] //Proceedings of the IEEE/CVF International Conference on Computer Vision. Los Alamitos: IEEE Computer Society Press, 2021: 13381-13392

[35] Tang T R, Jia J, Mao H Y. Dance with melody: an LSTM-autoencoder approach to music-oriented dance synthesis[C] //Proceedings of the 26th ACM international conference on Multimedia. New York: ACM Press, 2018: 1598-1606

[36] Le N, Pham T, Do T, *et al*. Music-driven group choreography[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2023: 8673-8682

[37] Lee H Y, Yang X D, Liu M Y, *et al*. Dancing to music[C] //Proceedings of the 33rd Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2019: 3586-3596

[38] Li B Y, Zhao Y C, Zhelun S, *et al*. DanceFormer: music conditioned 3d dance generation with parametric motion transformer[C] //Proceedings of the 36th AAAI Conference on Artificial Intelligence. Palo Alto: AAAI Press, 2022: 1272-1279

[39] Li S Y, Yu W J, Gu T P, *et al*. Bailando: 3D dance generation by actor-critic GPT with choreographic memory[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2022: 11040-11049

[40] Van Den Oord A, Vinyals O, Kavukcuoglu K. Neural discrete representation learning[C] //Proceedings of the 31st Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2017: 6309-6318

[41] Konda V R, Tsitsiklis J N. Actor-critic algorithms[C] //Proceedings of the 12th International Conference on Neural Information Processing Systems. Cambridge: MIT Press, 1999: 1008-1014

[42] Tseng J, Castellon R, Liu C K. EDGE: editable dance generation from music[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2023: 448-458

[43] Gleicher M. Retargetting motion to new characters[C] //Proceedings of the 25th Annual Conference on Computer Graphics and Interactive Techniques. New York: ACM Press, 1998: 33-42

[44] Tak S, Ko H S. A physically-based motion retargeting filter[J]. ACM Transactions on Graphics, 2005, 24(1): 98-117

[45] Lee J, Shin S Y. A hierarchical approach to interactive motion editing for human-like figures[C] //Proceedings of the 26th Annual Conference on Computer Graphics and Interactive Techniques. New York: ACM Press, 1999: 39-48

[46] Choi K J, Ko H S. Online motion retargeting[J]. The Journal of Visualization and Computer Animation, 2000, 11(5): 223-235

[47] Bernardin A, Hoyet L, Mucherino A, *et al*. Normalized euclidean distance matrices for human motion retargeting[C] //Proceedings of the 10th International Conference on Motion in Games. New York: ACM Press, 2017: Article No.15

[48] Feng A, Huang Y Z, Xu Y Y, *et al*. Automating the transfer of a generic set of behaviors onto a virtual character[C] //Proceedings of the 5th International Conference on Motion in Games. Heidelberg: Springer, 2012: 134-145

[49] Jang H, Kwon B, Yu M, *et al*. A variational U-Net for motion retargeting[C] //Proceedings of the SIGGRAPH Asia Posters. New York: ACM Press, 2018: Article No.1

[50] Kulkarni T D, Whitney W F, Kohli P, *et al*. Deep convolutional inverse graphics network[C] //Proceedings of the 28th International Conference on Neural Information Processing Systems. Cambridge: MIT Press, 2015: 2539-2547

[51] Ronneberger O, Fischer P, Brox T. U-net: convolutional networks for biomedical image segmentation[C] //Proceedings of the 18th International Conference on Medical Image Computing and Computer-Assisted Intervention. Heidelberg: Springer, 2015: 234-241

[52] Villegas R, Yang J M, Ceylan D, *et al*. Neural kinematic networks for unsupervised motion retargetting[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2018: 8639-8648

[53] Aberman K, Li P Z, Lischinski D, *et al*. Skeleton-aware networks for deep motion retargeting[J]. ACM Transactions on Graphics, 2020, 39(4): Article No.62

[54] Zhang J X, Weng J W, Kang D, *et al*. Skinned motion retargeting with residual perception of motion semantics & geometry[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2023: 13864-13872

[55] Loper M, Mahmood N, Romero J, *et al*. SMPL: a skinned multi-person linear model[J]. Seminal Graphics Papers: Pushing the Boundaries, 2023, 2: Article No.88

[56] Romero J, Tzionas D, Black M J. Embodied hands: modeling and capturing hands and bodies together[J]. ACM Transactions on Graphics, 2017, 36(6): Article No.245

[57] Pavlakos G, Choutas V, Ghorbani N, *et al*. Expressive body capture: 3D hands, face, and body from a single image[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2019: 10967-10977

[58] Zhou Y, Barnes C, Lu J W, *et al*. On the continuity of rotation representations in neural networks[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2019: 5738-5746

[59] Mahmood N, Ghorbani N, Troje N F, *et al*. AMASS: archive of motion capture as surface shapes[C] //Proceedings of the IEEE/CVF International Conference on Computer Vision. Los Alamitos: IEEE Computer Society Press, 2019: 5441-5450

[60] Alemi O, Françoise J, Pasquier P. GrooveNet: real-time music-driven dance movement generation using artificial neural networks[J]. Networks, 2017, 8(17): Article No.26

[61] Zhuang W L, Wang C Y, Xia S Y, *et al*. Music2Dance: DanceNet for music-driven dance generation[J]. ACM Transactions on Multimedia Computing, Communications, and Applications, 2022, 18(2): 1-21

[62] Sun G F, Wong Y, Cheng Z Y, *et al*. DeepDance: music-to-dance motion choreography with adversarial learning[J]. IEEE Transactions on Multimedia, 2021, 23: 497-509

[63] Adobe. Mixamo[OL]. [2024-08-22]. https://www.mixamo.com/

[64] Castellon R, Donahue C, Liang P. Codified audio language modeling learns useful representations for music information

最新录用

retrieval[C] //Proceedings of the 22nd International Society for Music Information Retrieval Conference. London: Ubiquity Press, 2021: 88-96

[65] Donahue C, Liang P. Sheet sage: lead sheets from music audio[C] //Proceedings of the 22nd International Society for Music Information Retrieval Conference. London: Ubiquity Press, 2021: 1-3

[66] Dhariwal P, Jun H, Payne C, *et al*. Jukebox: a generative model for music[OL]. [2024-08-22]. https://arxiv.org/abs/2005.00341

[67] Perez E, Strub F, De Vries H, *et al*. FiLM: visual reasoning with a general conditioning layer[C] //Proceedings of the 32nd AAAI Conference on Artificial Intelligence. Palo Alto: AAAI Press, 2018: 3942-3951

[68] Yang S C, Wu Z Y, Li M L, *et al*. DiffuseStylegesture: stylized audio-driven co-speech gesture generation with diffusion models[C] //Proceedings of the 32nd International Joint Conference on Artificial Intelligence. Freiburg: ijcai.org, 2023: 5860-5868

[69] Petrovich M, Black M J, Varol G. Action-conditioned 3D human motion synthesis with transformer VAE[C] //Proceedings of the IEEE/CVF International Conference on Computer Vision. Los Alamitos: IEEE Computer Society Press, 2021: 10965-10975

[70] Shi M Y, Aberman K, Aristidou A, *et al*. MotioNet: 3D human motion reconstruction from monocular video with skeleton consistency[J]. ACM Transactions on Graphics, 2020, 40(1): Article No.1

[71] Li Z, Zheng Z R, Wang L Z, *et al*. Animatable Gaussians: learning pose-dependent Gaussian maps for high-fidelity human avatar modeling[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2024: 19711-19722

[72] Işık M, Rünz M, Georgopoulos M, *et al*. HumanRF: high-fidelity neural radiance fields for humans in motion[J]. ACM Transactions on Graphics, 2023, 42(4): Article No.160

[73] Zhang B C, Zhang P, Dong X Y, *et al*. Long-CLIP: unlocking the long-text capability of clip[C] //Proceedings of the 18th European Conference on Computer Vision. Berlin: Springer, 2024: 310-325

[74] Song W F, Jin X L, Li S, *et al*. Arbitrary motion style transfer with multi-condition motion latent diffusion model[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2024: 821-830

最新录用