单目视频中着装人体重建的时空特征融合

周振华 [1)], 刘骊 [1,2)*], 付晓东 [1,2)], 刘利军 [1,2)], 彭玮 [1,2)]

[1)] (昆明理工大学信息工程与自动化学院　昆明　650500)
[2)] (昆明理工大学云南省计算机技术应用重点实验室　昆明　650500)
(ieall@kust.edu.cn)

摘　要: 针对单目视频输入的着装人体重建中模型形状结构不完整、局部细节预测不准确和运动模型不平滑的问题，提出一种着装人体重建的时空特征融合方法. 首先在观测空间与规范空间之间的变形场定义时序变形，对连续帧之间的上下文信息进行时序特征表示和加强；然后以时序特征引导细粒度空间特征的学习，获取着装人体的全局点级特征和像素对齐特征；最后提出基于自注意力的时空特征融合方法，得到具有时序信息的全局点级特征和像素对齐特征的融合特征，通过构建结合融合特征与规范空间坐标的神经辐射场重建准确的着装人体. 在 ZJU-MoCap 数据集上的新视角和新姿态实验结果表明，所提方法的 PSNR 总和分别为 190.96 dB 和 184.03 dB，较对比方法提升 10.65 dB 和 2.45 dB，能够提高着装人体重建的准确性，生成具有形状合理、服装纹理丰富和肢体平滑的着装人体模型；文本驱动模型的定性实验结果表明，该方法也具有一定的泛化性.

关键词: 单目视频着装人体重建；时序特征表示；空间特征学习；时空特征融合；神经辐射场
中图法分类号: TP391.41　　**DOI:** 10.3724/SP.J.1089.2024-00434

最新录用

Spatial-Temporal Feature Fusion for Clothed Human Reconstruction from Monocular Video

Zhou Zhenhua[1)], Liu Li[1,2)*], Fu Xiaodong[1,2)], Liu Lijun[1,2)], and Peng Wei[1,2)]

[1)] (*Faculty of Information Engineering and Automation, Kunming University of Science and Technology, Kunming*　650500)
[2)] (*Yunnan Key Laboratory of Computer Technologies Application, Kunming University of Science and Technology, Kunming*　650500)

Abstract: To address the problem of incomplete shape structure, inaccurate local details prediction and unsmooth motion model in clothed human reconstruction from monocular video, a spatial-temporal feature fusion method for clothed human reconstruction is proposed. Firstly, the temporal deformation is defined in deformation field between observe space and canonical space, representing and enhancing temporal features of contextual information between consecutive frames. Secondly, temporal features are used to guide the learning of fine-grained spatial features, obtaining global point-level features and pixel-aligned features of the clothed human body. Lastly, the spatial-temporal feature fusion module based on self-attention is proposed to obtain fusion features of global point-level features and pixel-aligned features with temporal information, and neural radiance fields is constructed that combines fusion features and canonical space coordinates to reconstruct accurate clothed human. Experimental results of the novel view and novel pose on ZJU-MoCap dataset show that total peak signal-to-noise ratio (PSNR) is 190.96 dB and 184.03 dB respectively, which is 10.65 dB and 2.45 dB higher than the comparison methods. The proposed method can improve ac-

收稿日期: 2024-07-26; 修回日期: 2024-12-23. **基金项目:** 国家自然科学基金(62262036, 62362043); 兴滇英才支持计划项目(KKXY202203008). **周振华**(2000—), 男，硕士研究生，CCF 学生会员，主要研究方向为计算机视觉; **刘骊**(1979—), 女，博士，教授，博士生导师, CCF 高级会员，论文通信作者，主要研究方向为计算机图形学、计算机视觉、图像处理; **付晓东**(1975—), 男，博士，教授，博士生导师, CCF 高级会员，主要研究方向为服务计算、决策理论与方法; **刘利军**(1978—), 男，博士，副教授, CCF 会员，主要研究方向为图像处理、云计算、信息检索; **彭玮**(1980—), 女，博士，教授，博士生导师, CCF 会员，主要研究方向为机器学习、数据挖掘.

curacy of clothed human reconstruction and generate clothed human models with reasonable shapes, rich clothing textures, and smooth limbs. Experimental results of text driven model show that the proposed method also has a certain degree of generalization ability.

Key words: monocular video clothed human reconstruction; temporal feature representation; spatial feature learning; spatial-temporal fusion; neural radiance fields

着装人体重建[1]是计算机视觉和计算机图形学交叉领域的一项重要任务，旨在通过图像和视频数据恢复高质量的三维着装人体模型，被广泛应用于体育娱乐、虚拟试穿、电影制作和医学研究等领域. 近年来，着装人体重建技术取得了非常显著的进展，根据实现方法的不同大致分为 4 类: (1) 基于显式表示的着装人体重建较为灵活[2]，通过构建明确的三维网格或点云来表示人体和服装的形状，模拟连续的人体曲面，能有效地表示宽松服装; (2) 基于隐式函数的着装人体重建[3]能够有效地表达复杂的人体形状和结构，且能精确地恢复服装表面纹理和褶皱细节，使得生成的模型更加逼真; (3) 基于神经辐射场(neural radiance fields, NeRF)的着装人体重建[4]能够模拟光照在人体和服装表面的传播和交互过程，实现令人印象深刻的视觉效果; (4) 基于三维高斯的着装人体重建方法[5]以快速的渲染方式逐渐受到科研工作者的关注，其简单的渲染流程能减少大量的训练时间，且能保证一定的渲染质量.

随着虚拟数字人技术的商业化进程加速，对着装人体重建模型的精度要求日益提升. 传统方法通常依赖于多视图图像. 文献[6]以相互正交的四视角图像作为输入，将服装视觉信息分为服装款式、着装层次和褶皱细节进行表示，以实现高精度的着装人体重建; Weng 等[7]引入姿势先验和基于优化的规范配置增强对未知姿势的泛化能力: 然而当观察视图变得稀疏时，这些方法的底层优化面临显著挑战. Peng 等[8]通过 SMPL[9]生成的结构化姿势特征调节辐射场，从稀疏多视图视频中生成自由视角的图像; Liu 等[10]结合 NeRF 和纹理映射，在 SMPL 的 UV 域中生成纹理映射，通过将姿态向量分解为多个身体部位并插值纹理特征来分层查询姿态特征，以合成更加细粒度的运动人体: 但是，以上方法通常依赖于精心收集的多视图图像或多视图视频，限制了其在通用和个性化场景中的适用性. 当前，单目视频作为一种日益普及的数据形式，已能满足不同应用场景的现实需求; 但由于单目视频的人体运动幅度大、深度信息和先验信息缺失等问题，导致在单目视频着装人体重建中面临人体模型形状结构不完整、局部细节预测不准确和运动模型不平滑等问题.

为了解决上述基于单目视频输入方法存在的问题，许多工作致力于通过改进 NeRF 进行重建，旨在降低复杂度的同时提高建模准确性. Wang 等[11]通过结合铰接的隐式曲面与体积渲染技术，实现了详细的几何表面建模，并通过改进射线表面交叉搜索和对应搜索的联合寻根算法，使模型很好地泛化至未见过的姿势; Guo 等[12]使用 2 个独立的 NeRF 分别对人体和背景进行建模，利用动态更新的规范人体正则化光线不透明性联合优化动态前景场和静态背景场，实现对野外视频的人体重建; Yu 等[13]则采用双向约束对变形场进行建模，通过分解前后变形对应为共享的骨骼运动权重和分离的非刚性运动，增强模型的姿势泛化能力，并利用关键帧信息推理特征相关性，指导渲染网络生成更具高保真度的结果; Xiang 等[14]通过改进渲染策略，利用多尺度机制寻找 SMPL 网格上的最近邻点构建参数化顶点集，预测被物体遮挡的人体模型: 然而，上述方法侧重于对模型算法的改进或增加对模型的约束，忽略了对输入数据中的时序信息和空间信息的深度提取，难以表示人体模型在时空关系中的连续运动和服装细节，使得重建结果出现不平滑、局部细节不准确和形状缺失等问题.

由于单目视频中蕴含丰富的时间信息，运动序列中任何帧的信息内容与其相邻帧的信息内容存在强关联性，且每个单独帧中运动人体包含的人体结构和服装细节等空间信息对于重建精确的几何结构和颜色细节至关重要. 因此充分利用这些信息之间的关联性，消除相互间的影响，是实现高精度着装人体重建的关键. 综上所述，目前，单目视频着装人体重建仍然面临以下难点: (1) 运动序列中着装人体的姿态形状和服装变化复杂，且连续帧之间的运动语义信息跨度大，导致难以充分利用相连帧之间的上下文信息; (2) 对于运动序列中的每个单独帧，全局人体结构信息和局部服装纹理信息对重建结果至关重要，但已有方法难

以有效地提取和利用这些空间信息; (3) 运动中的人体特征在时空域分布较散, 网络难以对它们进行有效融合, 导致几何误差随时间累积, 产生局部形状不平滑和模型轮廓模糊.

针对上述难点, 本文从单目视频人体运动序列中学习和重建着装人体模型. 通过在观测空间和规范空间连接的变形场中添加时间条件变形多层感知机(multilayer perceptron, MLP), 对单目视频中的三维着装人体进行时序特征学习, 补充视频中建模人体的姿势相关运动; 利用具有时序信息的观测空间和规范空间网格人体对网络进行指导, 学习得到点级特征和像素对齐特征, 提升对着装人体及服装表面细节建模的准确性; 改进自注意机制, 采用 Transformer 融合带有时序信息的 2 种空间特征, 并使用融合后的特征指导 NeRF 进行重建, 以保持时序一致性, 提升重建结果整体的平滑性, 提高重建结果的精度.

1 相关工作

基于显式表示的方法通过三维点云或网格模板对人体上的三维服装几何结构进行建模. Jiang 等[15]敏锐地捕捉到时间信息对重建的影响, 建立了基于门控循环单元(gated recurrent unit, GRU)的运动补偿网络来调整每帧的姿态参数, 并根据预测的姿态为每个时间帧预测新的潜在向量, 以更准确地预测每个顶点的偏移量; Ma 等[16]从多种类型的服装、身体、姿势的三维点云中, 训练了一个具有新颖局部服装几何特征的神经网络, 有效地表示不同服装的形状; Ma 等[17]提出用关节局部元素的表面编解码器建模着装人体的方法, 将关节运动引起的大规模变形与拓扑变化和局部服装变形明确分离, 再从局部特征回归局部几何, 解决现有神经表面元素的局限性; Zhao 等[18]提出一种基于锚点的变形模型, 用于从身体运动序列预测三维服装动画, 通过混合刚性变换和额外的非线性位移精确地变形服装网格模板; Yoon 等[19]提出一种紧凑的运动表示描述身体运动引起的二次运动的时变外观, 通过捕捉服装特定轮廓变形的时变语义图, 以及捕捉局部几何变化的表面法线来渲染运动人体的最终外观: 尽管以上方法能够较准确地恢复三维着装人体的姿态形状和服装曲面, 但在表示一致连续的运动人体方面仍显不足, 且难以学习相连帧之间丰富的上下文语义信息. 针对这一问题, 本文深入研究了视频中的运动人体时序特征学习, 将时序特征贯穿于整个 NeRF, 通过相连帧之间的相似信息优化建模人体的姿势相关运动.

目前, 基于 NeRF 的方法[20]在处理视频流方面展现出显著优势, 不仅提高模型的泛化能力, 还优化了渲染质量. Jayasundara 等[21]注意到人体运动随时间变化对建模的影响, 提出结合与姿势无关的时间变形和姿势相关的变形场, 重建更真实自由视点中的人体; Chen 等[22]专注于为任意的人类表演者合成高保真度的几何重建, 将几何体引导的注意力集中在聚合多视图外观和几何体代理上, 缓解三维几何体和像素空间之间的错位问题; Pang 等[23]将三维高斯函数附加到可变形的字符模型上, 并在二维纹理空间中学习它们的参数, 可以实时渲染更真实的动态人物; Liu 等[24]使用文本驱动三维高斯生成高质量的着装人体, 并提出结构感知分数蒸馏采样(score distillation sampling, SDS)和负负提示指引策略, 在明确的结构指导下共同学习人体外观和几何, 消除了人体模型的浮动伪影; Li 等[25]提出从人类表演者的单目视频中学习可推广的人类 NeRF 模型, 引入一种可见性感知的聚合方案计算顶点特征, 并与时间对齐的逐点特征一起预测密度和颜色进行着装人体的渲染; Hu 等[26]提出一组三维感知分层特征表示, 仅利用全局、点级和像素对齐等空间特征, 实现了从自由视图和新颖姿势进行渲染和动画制作: 尽管上述方法的着装人体重建精度较高, 但由于缺乏运动人体的时序信息作为指导, 容易使模型产生过拟合或重建偏差. 为此, 本文引入带有时序信息的人体模型指导网络, 对着装人体进行空间特征学习, 实现了从全局人体结构到局部服装细节的全面表示, 加强对运动中着装人体的人体表面和服装纹理的表达.

除了准确地跟踪时序一致的运动人体外, 如何精确地恢复服装表面细节也是着装人体重建的重点之一. He 等[27]使用占有图表示三维着装人体, 并添加图像网络进一步细化人体表面的详细几何结构和纹理; Cao 等[28]提出一种 SeSDF, 利用参数人体模型, 在未校准的情况下, 从任意数量的输入图像中重建精细的着装人体模型; Svitov 等[29]将神经纹理与人体网格模型相结合, 首先使用纹理操作和神经渲染重建人体, 然后用去噪扩散概率训练修复模型, 使重建的人体模型易于动画化和快速推断, 该模型适用于恢复输入图像中未显示的身体区域; Xiu 等[30]通过推断着装人体正面和背面的详细二维法线图, 恢复了 2.5D 的前后表面, 并

在身体网格的帮助下相互配准，实现了具有极端姿势和穿着挑战性服装的着装人体的同时重建. 但由于上述方法缺乏合适的特征来引导网络，对于存在深度模糊和姿态观测不足等问题的输入数据，仍可能产生局部浮动伪影. 针对这一问题，受到文献[31]的启发，本文在变形场引入时间条件变形 MLP 进行时序特征学习，并使用带有时序信息的网格人体指导网络进行空间特征的学习；将带有时序特征的每帧着装人体空间特征进行融合，并使用融合后的特征指导渲染网络进行重建，有效地提升了运动中着装人体模型的准确性和平滑性.

2 本文方法概述

本文方法的流程如图 1 所示，旨在通过单目视频运动序列实现着装人体的精确重建. 首先以单目视频帧作为输入，针对变形场中的时间相关前向变形和后向变形进行时序特征学习；然后在观测(姿态)空间直接提取 SMPL 顶点和在规范(标准)空间提取人体坐标，学习全局点级特征和像素对齐特征；提出融合时序信息的全局和局部空间特征的神经渲染方法，输出最终的着装人体.

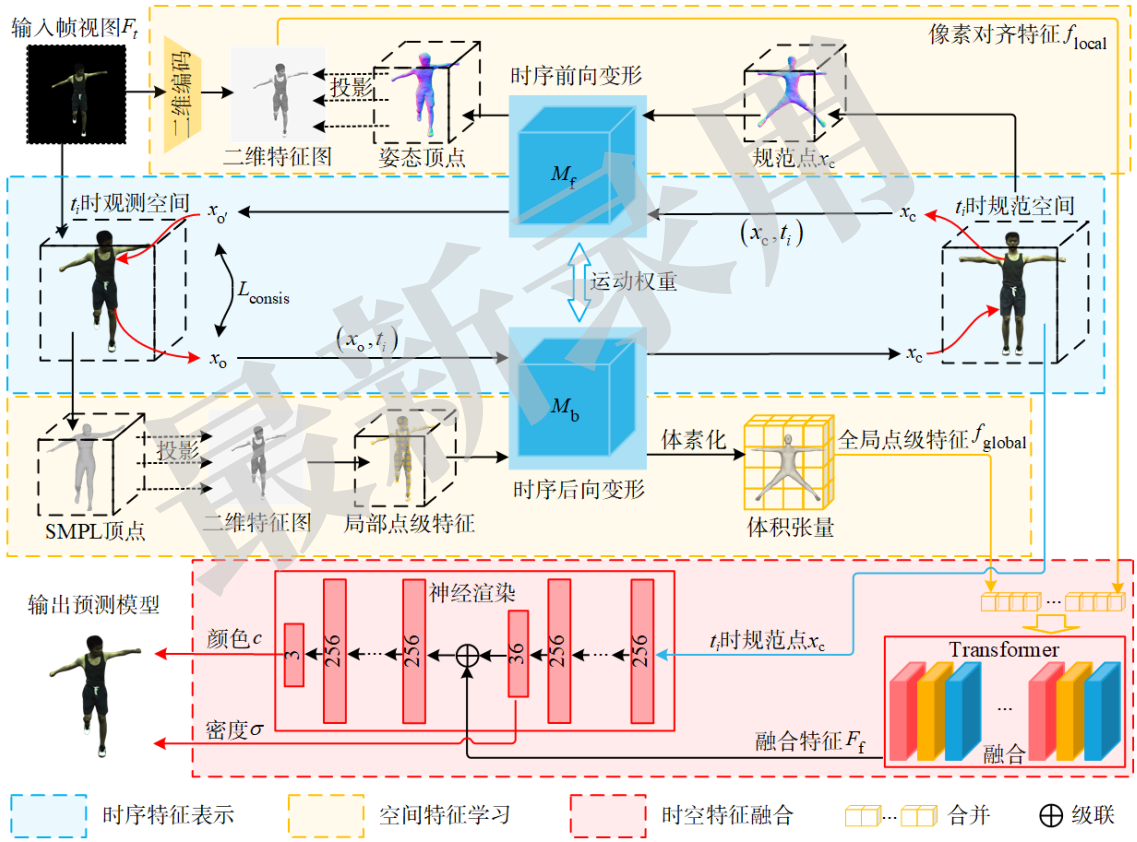

图 1 本文方法流程

(1) 构建单目视频时序特征表示模块，对每个时间步长的规范空间和观测空间之间的运动人体进行建模，既能够精确地捕捉运动人体在不同时间步长上的动态变化，又提高了对人体姿势相关运动建模的准确性.

(2) 设计着装人体空间特征学习模块，以带有时序信息的网格人体作为指导，有效提取全局点级特征和像素对齐特征，不仅优化了着装人体模型的空间信息表示，还确保了从全局到局部特征的连续性和一致性.

(3) 提出一种融合时序信息的全局和局部空间特征的方法，充分利用时序特征的优势指导 NeRF 重建最终的人体模型，提升着装人体模型的平滑性，进一步提升着装人体重建的准确性和逼真度.

3　时空特征融合

运动序列中的人体特征信息复杂多样，仅依赖单一网络难以精准地重建细节丰富的着装人体模型．因此，本文提出一种分阶段学习并融合时空特征的方法，通过构建时序特征表示、空间特征学习和时空特征融合 3 个模块，实现对运动序列中着装人体的精确重建．

与现有基于 NeRF 的方法类似，给定单目人体运动视频帧、相机参数、人体区域掩模和相应的 SMPL 参数 (θ,β)，本文采用 NeRF 在一个规范空间中表示来自观测空间的着装人体．将观测空间中点 x_{o} 的颜色和密度建模为包括时序后向和前向变形的映射函数

$$F_{\mathrm{r}}\left(M_{\mathrm{f}}\left(M_{\mathrm{b}}\left(x_{\mathrm{o}},t_i\right),F_{\mathrm{f}}\right)\right)\rightarrow c\left(x_{\mathrm{c}}\right),\sigma\left(x_{\mathrm{c}}\right).$$

其中，$M_{\mathrm{b}}(\cdot)$ 和 $M_{\mathrm{f}}(\cdot)$ 是以时间 t_i 和点 x_{o} 作为输入的时序后向和时序前向变形映射；输出规范空间中的该点 x_{c}，F_{r} 是一个以 x_{c} 和融合特征 F_{f} 为输入，并输出其颜色值 c 和密度值 σ 的映射网络．最终，在一个规范空间中采用神经体积渲染完成着装人体的绘制．该方法充分使用时序和空间特征，以及设计融合了时空特征的映射网络，更准确地描述运动序列中的着装人体外观和形态．

3.1　时序特征表示

由于着装人体在连续帧之间的运动语义信息跨度大，导致在一定程度上降低模型重建的平稳度，影响模型运动的一致连续性．现有方法往往只采用传统线性混合蒙皮网络(linear blend skinning, LBS)对观测空间中的模型进行变形，未考虑单目视频相邻帧之间的着装人体语义关联．为了充分利用相连帧之间运动人体的上下文信息，为后续模块提供有效的特征指导，受到文献[31]的启发，本文引入时间相关变形 MLP 对每个时间步长的规范空间和观测空间之间的运动进行建模，即将时序特征表示为观测空间与规范空间之间的时序变形．在规范空间中定义时序后向变形、时序前向变形和运动权重，其中，运动权重由时序变形 MLP 经过学习获得，并以 t_i 时观测空间与规范空间之间三维坐标互相变形的方式表示．为了有利于模型泛化至更多未见过姿态，运动权重的设计与姿态无关．给定 t_i 处的 x_{o}，通过预测时序后向变形

$$M_{\mathrm{b}}:(x_{\mathrm{o}},t_i)\rightarrow x_{\mathrm{c}} \tag{1}$$

可以将 x_{o} 变换至 x_{c}，然后使用 NeRF 中的位置编码函数，将输入的三维坐标 x_{o} 和时间步长 t 提升到 NeRF 和变形场的高维空间，以学习 NeRF 低维问题域中的高频函数．利用 NeRF 预测 x_{o} 在 t_i 处的 c 和 σ．

文献[31]引入辅助运动流网络，将规范空间中的三维坐标逆变换回每个观测空间中的三维坐标；与此不同，本文提出的时序前向变形采用与时序后向变形相同的运动权重，将 x_{c} 变换回观测空间三维坐标 $x_{\mathrm{o}'}$，在降低算法复杂度和减少训练时间的同时增强运动人体的时序一致性．时序前向变形定义为

$$M_{\mathrm{f}}:(x_{\mathrm{c}},t_i)\rightarrow x_{\mathrm{o}} \tag{2}$$

时序前向变形和时序后向变形将时序特征信息有效地融入整个着装人体重建中．

为了进一步增强运动的一致性，本文添加仅与变形场相关的前后变形一致性损失，通过对原观测空间 x_{o} 三维坐标和变换后返回的观测空间三维坐标 $x_{\mathrm{o}'}$ 进行对比优化，使变形场随着时间的推移加强运动一致性，并正则化变形场中时间变形的误差．一致性损失计算公式为

$$L_{\mathrm{consis}}=\begin{cases}d, & \text{if } d\geqslant\theta\\ 0, & \text{else}\end{cases} \tag{3}$$

其中，$d=L_2\left(x_{\mathrm{o}},M_{\mathrm{f}}\left(M_{\mathrm{b}}\left(x_{\mathrm{o}},t_i\right),t_i\right)\right)$，$L_2$ 表示 L_2 距离损失的计算；损失函数只正则距离 d 大于阈值 θ 的点，以避免其过度正则化．一致性损失使观测空间和规范空间形成循环，强制 2 种观测空间之间的双向流动，通过规范空间和变形场加强模型的运动一致性，更有效地表达了着装人体的时序信息．

3.2　空间特征学习

时序特征表示模块从单目视频帧中捕获了带有时序信息的着装人体粗略模型，而单目视频帧中还包含丰富的服装纹理和褶皱细节，但仅从视频帧中提取空间特征并不能准确地恢复服装运动相关的纹理细节．为了获取单目视频中着装人体更多运动相关的细粒度信息，本文使用时序特征模块指导空间特征学习的策略，采用由全局到局部的流程结构，包括全局的点级特征和局部的像素对齐特征，从带有时序信息的观测空间和规范空间中进行空间特征的学习．本文构建的空间特征学习模块在保持时序一致的同时，能有效地加强恢复服装纹理．

3.2.1　全局点级特征

针对运动中着装人体的全局结构和整体外观，以及单目视频无法完整地捕捉到的人体背面区域的问题，本文采用全局点级特征进行全局空间信息的学习和预测. (1) 通过残差网络对 t_i 时输入的帧视图 F_t 进行二维编码，获取当前帧视图的二维特征图. (2) 从 t_i 时的观测空间提取 SMPL 顶点，将该顶点投影到当前帧视图得到投影后的 UV 坐标，对 UV 坐标进行双线性插值提取可见部分顶点特征. 由于 SMPL 顶点在投影过程中可能无法完全映射至着装人体的有效区域，因此采用 SMPL 的掩模机制排除未在图像中可见的顶点特征，确保网络更好地学习图像中可见部分的特征. (3) 对顶点特征进行卷积操作，生成可见部分顶点的卷积张量.

对于当前帧视图不可见部分的顶点，采用时序信息引导空间信息学习的方法，在保持模型平稳性的同时，准确地学习不可见部分顶点的卷积张量. 首先利用时序特征模块中的时序后向变形，将 SMPL 顶点转换至规范 SMPL 顶点；然后将规范 SMPL 顶点体素化为稀疏三维体积张量，并通过稀疏三维卷积进一步处理，得到不可见部分的卷积张量；最后将可见部分与不可见部分顶点的卷积张量作为稀疏卷积编码的输入，从编码的稀疏三维体积张量中提取全局点级特征. 全局点级特征定义为

$$f_{\text{global}} = \Pi\left(W\left(F_t\right)\right) + M_{\text{b}}\left(\text{SMPL}, \theta, \beta\right) \tag{4}$$

其中，$W(\cdot)$ 表示二维编码器；$\Pi(\cdot)$ 表示三维到二维的投影算子；F_t 是 t_i 时的帧视图；$M_{\text{b}}(\cdot)$ 将 SMPL 顶点、姿态 θ 和形状 β 变换至规范空间中的规范 SMPL 顶点.

3.2.2 像素对齐特征

点级特征主要描述整体着装人体结构，而单目视频中的可见部分通常包含丰富的局部服装褶皱和纹理细节，本文进一步学习像素对齐特征，恢复这些更加细粒度的局部空间信息. (1) 从 t_i 时规范空间提取 x_{c}，并采用与全局点级特征类似的策略处理所有顶点以获取有效点，利用 K 最近邻算法(K-nearest neighbor, KNN)，在 SMPL 人体模型顶点集合中查找与规范顶点最近的顶点，并计算它们之间的距离. 若距离小于指定的阈值，则将采样点标记为有效点. (2) 通过时序前向变形将有效的 x_{c} 转换为观测空间的姿态顶点，由于时序变形采用了相同的运动权重，因此能显著降低形变误差，为像素对齐特征的学习提供更合理的姿态顶点. (3) 将姿态顶点分别投影到当前帧视图 F_t，得到对应的 UV 坐标，并通过双线性插值，从当前帧视图的二维特征图和颜色信息中提取像素特征和像素颜色. (4) 将像素特征和像素颜色作为位置编码的输入，通过编码得到最终的像素对齐特征. 像素对齐特征的定义为

$$f_{\text{local}} = \Pi\left(W\left(F_t\right)\right) + M_{\text{f}}\left(x_{\text{c}}, \theta, \beta\right) \tag{5}$$

其中，时序前向变形 M_{f} 将 x_{c} 变换至观测空间中具有姿态 θ 和形状 β 的姿态顶点.

3.3 时空特征融合

为了有效地结合第 3.2 节中学习到的全局点级特征和像素对齐特征，指导 NeRF 的渲染网络，本文提出一种基于自注意力的 Transformer 模型实现时空特征融合，旨在融合全局人体结构和服装的局部细节，形成着装人体的融合特征.

首先将带有时序信息的 f_{global} 和 f_{local} 进行拼接，并通过卷积投影操作进行预处理，获得初始的融合特征卷积张量 $\boldsymbol{C}$；然后，将卷积张量 $\boldsymbol{C}$ 作为输入，构建基于 Transformer 的自注意特征融合模块，并更改其自注意力模块 $\text{A}(\cdot)$ 的结构，对包含点级特征和像素对齐特征的空间特征进行特征融合，得到 F_{f}，表示为

$$F_{\text{f}}\left(f_{\text{global}}, f_{\text{local}}\right) = \text{A}\left(\text{Softmax}\left(\frac{\boldsymbol{Q}\boldsymbol{K}^{\text{T}}}{\sqrt{\text{dim}}}\right)\boldsymbol{V}\right) \tag{6}$$

其中，查询矩阵 $\boldsymbol{Q}$、密钥矩阵 $\boldsymbol{K}$ 和值矩阵 $\boldsymbol{V}$ 使用 MLP 投影特征获得；dim 表示缩放系数，$\text{Softmax}(\cdot)$ 表示激活函数.

本文在一个规范空间中执行渲染，在 F_{f} 的指导下，神经渲染网络将 x_{c} 和 F_{f} 作为输入，并输出对应点的 c 和 σ，整个神经渲染网络表示为一个映射函数 F_{r}. 将输入的空间点和特征映射到颜色空间和密度空间，定义为

$$c\left(x_{\text{c}}\right), \sigma\left(x_{\text{c}}\right) = F_{\text{r}}\left(\gamma\left(x_{\text{c}}\right), F_{\text{f}}\right) \tag{7}$$

其中，$\gamma(\cdot)$ 表示正弦位置编码. 最终，利用 NeRF 的体绘制方程在规范空间中绘制出着装人体模型，实现对视频中着装人体的高质量重建和渲染.

时空特征融合方法步骤如下：

Step1. 时序特征表示. 对输入着装人体数据集 $D = \{D_1, D_2, \cdots, D_n\}$ 中的单目视频帧 $F_t \in D$，通过式(1)(2)在观测空间和规范空间之间进行时序特征学习，将时序特征信息融入整个着装人体重建中，并通过式(3)强化时序信息的表达.

Step2. 空间特征学习：

Step2.1 在观测空间提取 SMPL 顶点，获取可见部分的顶点特征，再采用 Step1 中的时序后向变形结合式(4)操作，将 SMPL 顶点变形至规范空间，提取全局的点级特征 f_{global}.

Step2.2 在规范空间提取 x_{c}，采用 Step1 中的时序前向变形结合式(5)操作，将 x_{c} 变形至观测空间，再通过采样和编码获取像素对齐特征 f_{local}.

Step3. 时空特征融合. 构建并更改 Transformer 编码器的 $\mathrm{A}(\cdot)$，将 Step2.1 和 Step2.2 得到的 f_{global} 和 f_{local} 通过式(6)进行有效融合，得到融合特征 F_{f}. 最后，结合规范空间的 x_{c}，采用式(7)重建最终的精细着装人体.

3.4 损失函数

本文方法采用端到端的训练方式，旨在通过输入视频帧和预测的渲染视图进行高质量的监督学习. 为了更有效地训练网络并优化性能，在第 3.1 节的时序特征表示一致性损失基础上引入 2 种额外的损失函数.

(1) 光度损失. 用于度量输入视频帧和预测渲染视图之间的亮度一致性. 给定输入视频帧 $C(r)$ 和预测的渲染视图 $\hat{C}(r)$，光度损失定义为

$$L_{\text{color}}=\frac{1}{|R|}\sum_{r\in R}\left\|\hat{C}(r)-C(r)\right\|_2^2.$$

其中，射线集 R 包括所有射线 r，$|R|$ 表示 R 中的射线数. 光度损失通过计算每个射线对应的像素亮度差异，反映了模型在亮度保持方面的性能.

(2) 学习感知图像块相似度(learned perceptual image patch similarity, LPIPS)损失. 作为一种感知损失，旨在保证渲染视图在视觉质量上与真实图像接近. 该损失通过预训练的神经网络提取图像的高层特征，并计算这些特征之间的差异，定义为

$$L_{\text{LPIPS}}=\text{LPIPS}\left(\hat{C}(r),C(r)\right).$$

最终，总的损失函数由时序特征表示一致性损失、光度损失和 LPIPS 损失 3 部分组成，表示为

$$L=L_{\text{color}}+\lambda L_{\text{LPIPS}}+L_{\text{consis}}.$$

其中，λ 表示损失权重值，用于平衡不同损失项之间的贡献. 根据经验，本文将 λ 设置为 0.01，确保每个损失项与其他损失项在数量级上相近. 通过降低总损失函数的值，模型在训练过程中不断优化，提升渲染性能和视觉效果.

4 实验结果及分析

4.1 数据集及实验设置

本文将目前着装人体重建领域最广泛使用的基准数据集 ZJU-MoCap[8]作为实验的训练集和测试集. ZJU-MoCap 用于评估多视图视频和单目视频中的动态人体重建，包含 21 个同步摄像头构成的多摄像头系统，表演者执行包括旋转、摆动手臂、挥拳和踢脚等任意复杂的运动，本文从 9 位表演者中选取 6 位的数据用于训练和测试. 由于 ZJU-MoCap 是在室内环境中精心收集的，因此在实验中直接使用该数据集提供的注释. 根据文献[7]的数据集设置，本文仅使用 ZJU-MoCap 中的相机 1 数据进行训练. 选取数据集中的 6 位表演者，并在 2 种情况下将本文方法与基线方法进行比较. 在“新视角”下，使用一个表演者的前 4/5 帧作为训练帧，其他 22 个摄像机的同步帧作为评估帧；在“新姿势”下，同样使用一个表演者的前 4/5 帧作为训练帧，剩余 1/5 帧及其在其他 22 个摄像机中的同步帧作为评估帧.

实验在 Intel Core i9-13900k CPU @5.80 GHz, NVIDIA GeForce RTX 4090 GPU, 32 GB DDR5 RAM × 4 硬件平台进行；在 Ubuntu20.04 系统下，使用 Pytorch1.11.0 框架搭建深度学习模型. 采用 NeRF 进行着装人体重建，并使用 Adam 优化器以端到端的方式进行训练. 为变形网络设定不同的初始学习率，学习率衰减的迭代次数为 500, batch-size 大小设置为 1，对每个表演者训练 150 000 幅视频帧.

4.2 评估指标

采用 NeRF 领域最常用的 3 个指标进行评估：(1) 峰值信噪比(peak signal to noise ratio, PSNR). 用于衡量图像质量，通过比较原始图像与经过压缩或处理后的图像之间的差异进行评估，其值越高，表明重建图像与原始图像之间的差异越小，即图像质量越好. (2) 结构相似性指数(structural similarity index, SSIM). 用于评估 2 幅图像之间结构的相似性，衡量了 2 幅图像之间的相似程度或失真程度；SSIM 的计算基于图像的亮度、对比度和结构相似性，其值域为 0 到 1，值越接近 1，表示 2 幅图像越相似. (3) LPIPS. 利用深度学习模型学习图像相似性度量，通过预训练的深度神经网络(如 VGG 等)计算图像之间的感知差异，其值越小，表示 2 幅图像之间的感知差异越小，图像质量越接近.

4.3 消融实验

4.3.1 时序特征表示有效性分析

通过依次移除每个组件至基础模型，在 ZJU-MoCap 数据集的表演者 377 上进行消融定量和定性实验，以分析本文方法中各模块的有效性. 如图 2 所示，为了验证时序特征表示的有效性，采用时间相关变形 MLP 的时序后向变形和时序前向变形策略，通过训练 3 个不同的 epoch 对常见的 LBS 和 LBS^{-1} 变形进行定性实验，结果如表 1 所示. 可以看出，基于 LBS 的变形在四肢区域均会产生不符合输入视图的扭曲；本文提出的时序变形模块更注重学习相连帧中着装人体相似的姿态信息，即使在训练不同 epoch 的情况下，也能更准确地重建形状更符合真实的着装人体模型.

表 1 时序特征有效性定性实验结果

epoch	输入	LBS	本文方法
100	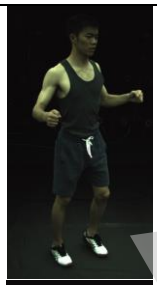	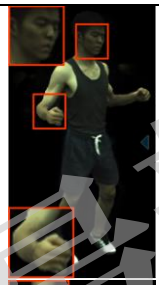	
200			
300			

4.3.2 空间特征学习有效性分析

在测试集上，对不同空间特征进行消融定量实验，结果如表 2 所示. 其中，Base 表示只使用时序特征、无空间特征、无特征融合的基准模型；GF, LF 分别表示全局点级特征和像素对齐特征，Base+GF+LF 表示采用直接级联的方式. 可以看出，本文提出的时序特征引导由粗到细的空间特征学习策略，能提升着装人体重建的精度，其中，当模型为 Base+GF 或者 Base+LF 时，均能有效地提升指标结果；在 Base 的基础上同时增加 GF 和 LF 时，SSIM 和 LPIPS 这 2 个指标能得到更好的结果，分别为 0.972 3 和 0.027 6，表明重建图像和真实图像之间的结构更相似，且感知差异缩小，但 PSNR 指标有一定程度的下降，这是因为特征级联后的模型在重建图像和真实图像时会引入一些误差，导致与原始图像的差异性增大，综合考虑 SSIM 和 LPIPS 指标的提升，说明特征级联策略在整体上提升了着装人体重建的质量.

表 2 空间特征学习有效性分析定量结果

模型	PSNR/dB↑	SSIM↑	LPIPS↓
Base	30.95	0.964 4	0.034 6
Base+GF	**31.19**	0.969 7	0.031 0
Base+LF	31.00	0.970 0	0.030 3
Base+GF+LF	30.77	**0.972 3**	**0.027 6**

注. 粗体表示最优值.

通过空间特征学习模块的定性消融实验，进一步展示全局点级特征和像素对齐特征的有效性，重建的可视化结果如图 2 所示.

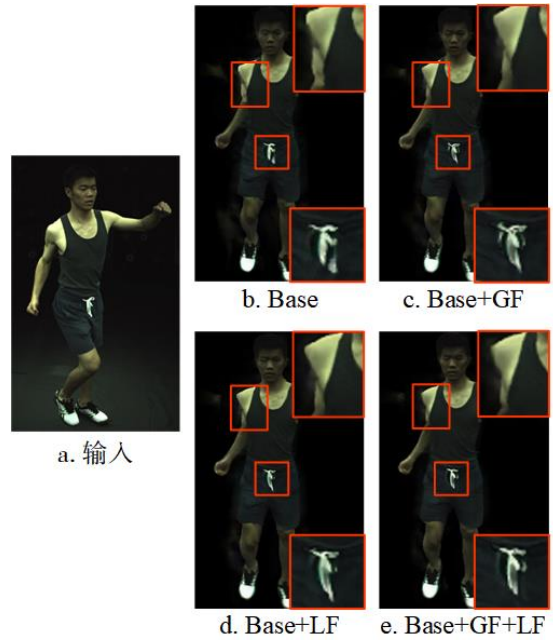

图 2 空间特征学习有效性分析定性结果

从图 2 可以看出，时序特征模块提供了粗略的着装人体模型，如图 2c 中着装人体的右肩、右臂和上衣所示，当在时序特征的基础上增加 GF 特征时，能重建更符合输入的人体结构和服装轮廓的人体模型；如图 2d 中的腰带配饰所示，当在时序特征的基础上增加 LF 特征时，能提升服装细节的预测精度. 实验结果表明，通过学习全局点级

最新录用

特征和像素对齐特征，能够提升重建着装人体的局部细节的预测精度.

4.3.3　时空特征融合有效性分析

将本文提出的基于自注意力机制的 Transformer 时空特征融合策略，与传统的特征级联及特征相加方式进行消融实验，验证时空特征融合的有效性，定量对比结果如表 3 所示. 可以看出，与简单的特征相加和级联策略相比，本文提出的 Transformer 时空特征融合策略在 3 项指标上均显著提升，说明采用本文方法重建的图像与真实图像之间的误差更小，两者在亮度和结构上相似度更高，且对人体结构和服装细节的感知和表示更准确，证明了特征融合模块能有效地提升着装人体的连续性和平滑性.

表 3　特征融合消融分析定量结果

特征融合方式	PSNR/dB↑	SSIM↑	LPIPS↓
特征级联	30.77	0.9723	0.0276
特征相加	31.09	0.9728	0.0287
本文方法	**31.37**	**0.9767**	**0.0254**

注. 粗体表示最优值.

进一步，对不同特征融合方式的定性结果进行实验，重建结果如图 3 所示. 可以看出，虽然空间特征的学习能增强人体结构和服装细节的表示，但在人体较为柔软的肢体区域易产生伪影. 从图 3 可以看出，无论是直接相加还是级联空间特征，均会产生较明显的伪影；本文构建的 Transformer 时空特征融合策略能显著地增强着装人体模型的平滑性，提高着装人体模型重建的准确性.

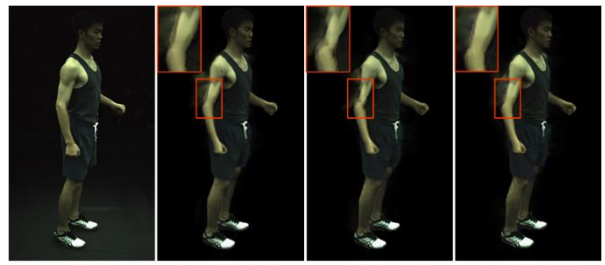

a. 输入　b. 特征级联　c. 特征相加　d. 本文方法

图 3　时空特征融合有效性分析定性结果

4.4　对比实验

4.4.1　定量对比

为了全面评估本文方法在着装人体新视图合成的性能，选取当前主流 NeRF 方法 NeuralBody[8]，HumanNeRF[7]和基线方法 MonoHuman[13]进行实验，在 ZJU-MoCap 数据集上，从新视角和新姿态 2 个维度进行深入的比较与定量分析. 其中，所有对比方法的数据均源自原文献及开源代码的复现结果.

(1) 新视角分析. 为了验证模型在不同视角下的着装人体重建迁移能力，在 ZJU-MoCap 数据集 6 个表演者测试集上，将本文方法与对比方法进行实验，结果如表 4 所示.

表 4　新视角定量结果比较

方法	S377			S386			S387		
	PSNR/dB↑	SSIM↑	LPIPS↓	PSNR/dB↑	SSIM↑	LPIPS↓	PSNR/dB↑	SSIM↑	LPIPS↓
NeuralBody[8]	29.29	0.9693	0.0394	30.71	0.9661	0.0458	26.36	0.9520	0.0622
HumanNeRF[7]	29.91	0.9755	0.0238	32.62	0.9672	0.0393	28.01	0.9634	0.0352
MonoHuman[13]	30.77	**0.9787**	**0.0216**	32.97	**0.9733**	**0.0327**	27.93	0.9633	**0.0334**
本文方法	**31.10**	0.9720	0.0343	**34.47**	0.9581	0.0552	**30.96**	**0.9650**	0.0411

方法	S392			S393			S394		
	PSNR/dB↑	SSIM↑	LPIPS↓	PSNR/dB↑	SSIM↑	LPIPS↓	PSNR/dB↑	SSIM↑	LPIPS↓
NeuralBody[8]	28.97	0.9615	0.0570	27.82	0.9577	0.0592	28.09	0.9557	0.0596
HumanNeRF[7]	30.95	0.9687	0.0342	28.43	0.9609	0.0362	28.52	0.9573	0.0397
MonoHuman[13]	31.24	**0.9715**	**0.0310**	28.46	0.9622	**0.0342**	28.94	0.9612	0.0359
本文方法	**32.17**	0.9695	0.0358	**31.10**	**0.9709**	0.0360	**31.16**	**0.9662**	**0.0346**

注. 粗体表示最优值，下划线表示次优值.

从表 4 可以看出，与对比方法相比，时序特征表示模块使新视角着装人体重建模型的误差更小，本文方法的 PSNR 指标均优于对比方法；在 SSIM 指标和 LPIPS 指标上，本文方法与基线方法基本持平，表明新视角着装人体重建后的整体模型结构与对比方法基本一致. 在 6 个新视角测试集上，本文的 PSNR 指标均优于基线方法，PSNR 总和较基线方法提升 10.65 dB，证明了该方法能重建形

录用稿

状和姿态更准确的着装人体；由于新视角测试集表演者 S377 和 S386 只包含简单的动作和少量的服装纹理，当前基线方法都能较好地处理，导致本文方法在这 2 个测试集上的 SSIM 和 LPIPS 指标略低于对比方法；对其余的 S387, S392, S393 和 S394 这 4 个动作幅度较大且服装纹理较多的测试集，本文方法的 SSIM 和 LPIPS 指标大多达到最优或次优结果，证明该方法能有效地重建复杂姿态和更多服装褶皱.

(2) 新姿态分析. 为了验证本文方法对未见过的视频帧的泛化能力，将新姿态测试集设置为 ZJU-MoCap 数据集中表演者后 1/5 视频帧，并确保这些视频帧中的动作都是未见过的姿态. 表 5 所示为本文方法与对比方法在 ZJU-MoCap 测试集上的新姿态定量实验结果. 可以看出，在所有 6 个新姿态测试集中，本文方法有 5 个 PSNR 指标取得最优值，且 PSNR 总和较基线方法提升 2.45 dB，说明对于未见过的姿态，该方法仍能准确地恢复着人体的形状；由于新姿态测试集中的 S386, S387 和 S394 视频帧较少，且动作幅度较小，未能较好地体现本文时空特征融合的特点；在姿态差距大和服装褶皱较多的 S377, S392 和 S393 新姿态测试集上，本文方法的 SSIM 和 LPIPS 指标都能达到最优值或次优值. 实验结果表明，在新姿态测试集上，本文方法的 PSNR 指标大部分优于对比方法，而 SSIM 和 LPIPS 指标也能与对比方法持平，证明了在新姿态的重建上，本文方法不仅拥有较好的泛化能力，同时对恢复复杂的服装褶皱也能取得良好的表现.

表 5 新姿态定量结果比较

方法	S377			S386			S387		
	PSNR/dB↑	SSIM↑	LPIPS↓	PSNR/dB↑	SSIM↑	LPIPS↓	PSNR/dB↑	SSIM↑	LPIPS↓
NeuralBody[8]	29.08	0.967 9	0.041 1	29.76	0.964 7	0.046 9	26.84	0.953 5	0.060 8
HumanNeRF[7]	29.79	0.971 4	0.028 4	32.10	0.964 2	0.041 8	28.11	0.962 5	0.037 4
MonoHuman[13]	30.46	**0.978 1**	**0.020 9**	32.99	**0.975 6**	**0.030 9**	28.40	**0.963 9**	**0.035 0**
本文方法	**31.37**	0.976 7	0.025 4	**33.08**	0.951 8	0.061 2	**28.90**	0.958 0	0.048 5

方法	S392			S393			S394		
	PSNR/dB↑	SSIM↑	LPIPS↓	PSNR/dB↑	SSIM↑	LPIPS↓	PSNR/dB↑	SSIM↑	LPIPS↓
NeuralBody[8]	29.49	0.964 0	0.051 0	28.50	0.959 1	0.057 0	28.65	0.957 2	0.055 7
HumanNeRF[7]	30.20	0.963 3	0.040 0	28.16	0.957 7	0.040 8	29.28	0.955 7	0.041 9
MonoHuman[13]	30.98	0.971 1	**0.030 8**	28.54	0.962 0	**0.034 9**	**30.21**	**0.964 2**	**0.032 8**
本文方法	**32.39**	**0.971 3**	0.034 7	**29.60**	**0.964 0**	0.038 5	28.69	0.958 5	0.040 6

注. 粗体表示最优值，下划线表示次优值.

4.4.2 定性对比

在 ZJU-MoCap 数据集上，从新姿态、新视角和文本驱动模型 3 个方面，与基线方法 MonoHuman[13] 和 GHuNeRF[25]进行定性实验，展示本文方法的有效性.

(1) 新视角分析. 在 6 个新视角测试集上，3 种方法的定性实验结果如表 6 所示. 其中，输入的视频帧中包含简单动作、大幅度动作、简单服装和多纹理服装等众多要素. 可以看出，与 GT 相比，MonoHuman[13]和 GHuNeRF[25]方法均不能准确地重建着装人体，而本文方法能得到相对准确且合理的重建结果；S377 和 S386 中，本文方法能准确地还原表演者手臂的重建，而现有方法重建的手臂存在明显的伪影或截断现象；在 S387 和 S394 中，现有方法并不能有效地学习较多纹理褶皱的服装，而本文方法重建的服装褶皱结果更接近 GT；S392 和 S393 是拥有更复杂姿态的视频帧，本文方法还原的手臂和膝关节更平滑，而现有方法重建的手臂和膝关节结果较为模糊或存在扭曲. 实验结果表明，本文方法在面对合理形状表示、丰富纹理服装学习和复杂姿态重建时，能表现出更高的准确性.

最新录用

表 6　新视角定性结果对比

测试集	新视角输入	GHuNeRF[25]	MonoHuman[13]	本文方法	GT
S377	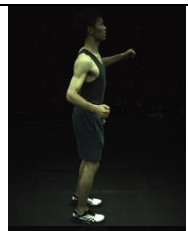				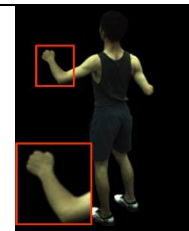
S386	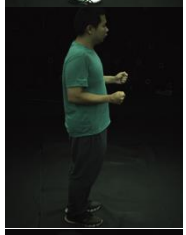	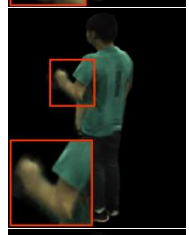		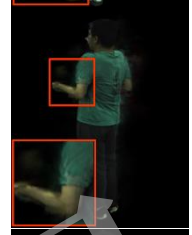	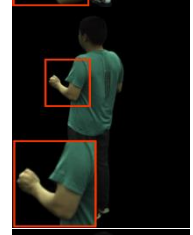
S387		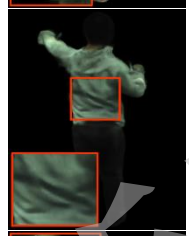	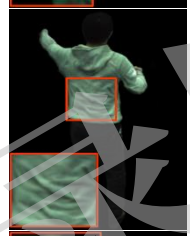	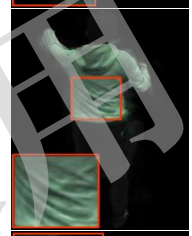	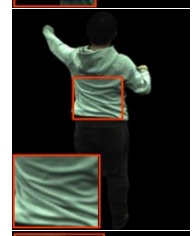
S392		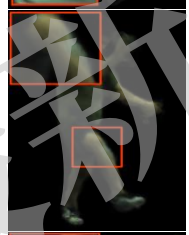			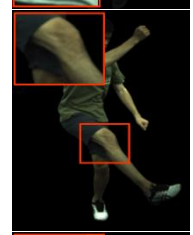
S393	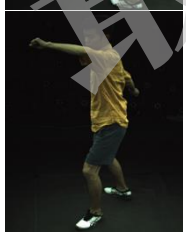				
S394					

最新录用

(2) 新姿态分析．在新姿态测试集上，对涵盖了简单动作、简单服装、复杂姿态和多褶皱的服装等情况进行实验，验证本文方法对新姿态定性结果上的适用性，结果如表 7 所示．从表 7 可以看出，对于简单动作和纯色服装的 S377 和 S392 的新姿态重建，本文方法能够复现更加接近 GT 的形状，如 S377 的手臂和 S392 的手掌部位，而对比方法重建的模型与 GT 的形状差异较大．对于含有复杂纹理和较多配饰的 S386 和 S387 新姿态重建，本文方法也能达到良好的效果．例如，对比方法在表达 S386 上衣时，容易产生大量与 GT 不相符的伪影，而本文在重建这些服装边缘时获得了更合理的效果；S387 中包含较多配饰，对比方法未能较好地关注到如该表演者的帽子和肩上的图案等细节，而本文方法能较为准确地捕获到这些配饰和图案，得到更接近 GT 的结果．新姿态测试集

S393 和 S394 都是包含大幅度动作的测试集，对比方法在四肢的重建上容易出现伪影或产生扭曲，而本文方法在面对复杂姿态时仍能较为准确且更平滑地重建着装人体．实验结果表明，本文方法在处理未见过的新姿态时展现出了良好的适用性和稳定性，无论是简单动作、复杂纹理还是大幅度动作，都能有效地进行高质量重建，比现有 NeRF 方法具有一定的优势．

表 7　新姿态定性结果对比

测试集	GHuNeRF[25]	MonoHuman[13]	本文方法	GT
S377		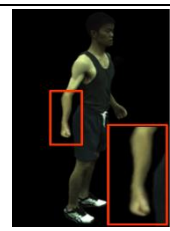		
S386			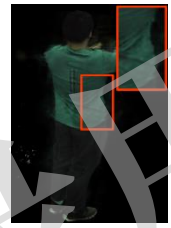	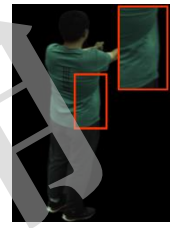
S387				
S392				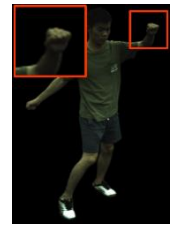
S393				
S394				

最新录用

(3) 文本驱动．通过文本输入生成挑战姿态序列来驱动模型，进一步验证本文方法对未见过数据的泛化性能，并进行定性实验．采用文本生成姿势序列的方式生成向上挥舞双手和高踢腿 2 种困难姿势，以动画的方式驱动对比方法和本文重建的着装人体模型，对 ZJU-MoCap 数据集中的表演者 S377 和 S393 分别进行向上挥舞双手和高踢腿这 2 种动作的实验，结果如表 8 所示．可以看

出，对比方法对 S377 向上挥舞双手的动作会产生不合理的形状和配饰，如扭曲的手臂和下装的腰带；而本文方法重建的模型展现出更符合动力学运动中着装人体的肢体和配饰，得到更自然的肢体和配饰形态．在 S393 执行高踢腿动作中，对比方法仍无法较好地处理被遮挡或高难度姿态下的肢体，如重建的站立模型腿部存在明显的截断现象，抬腿动作时腿部形状出现缺失和伪影；相比之下，本文方法在重建并驱动该模型执行此类高难度动作时，展现了良好的泛化性，有效地避免了肢体形状截断和伪影的出现．实验结果表明，在应对文本驱动复杂动作时，本文方法重建的模型能够更准确地重建人体形态和配饰，提供更符合实际的重建结果，验证了该方法的鲁棒性和泛化性．

表 8　文本驱动模型定性结果对比

测试集	MonoHuman[13]	本文方法	MonoHuman[13]	本文方法
S377	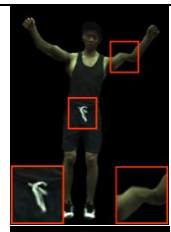			
S393				

5　结　语

针对单目视频输入的着装人体重建结果存在形状缺失、局部细节不准确和出现不平滑等问题，本文通过构建时序特征表示、空间特征学习和时空特征融合模块，提出一种着装人体重建的时空特征融合方法．其中，时序特征表示模块加强了对一致连续的运动人体的表征能力，生成具有合理形状和姿态的粗糙人体模型；空间特征学习模块在时序特征的指导下，学习运动中着装人体的全局人体结构和局部服装细节，优化人体结构和服装纹理的表达效果；时空特征融合模块对全局点级特征和像素对齐特征进行融合，提升了着装人体连续性和平滑性．

本文方法虽然能够实现较为准确且平滑的着装人体重建，但由于较多的特征学习易导致过拟合，产生少量伪影；此外，该方法局限于室内单目视频的输入，较难适应野外场景中光照、相机视角等因素的影响，获得理想结果．未来将围绕上述问题开展研究，进一步优化模型并提高在野外场景中着装人体重建的准确率和精度．

参考文献(References):

[1] Yan Yichao, Cheng Yuhao, Chen Zhuo, *et al*. A survey on generative 3D digital humans based on neural networks: representation, rendering, and learning[J]. SCIENTIA SINICA Informationis, 2023, 53(10): 1858-1891(in Chinese)
(晏轶超，程宇豪，陈琢，等．基于神经网络的生成式三维数字人研究综述：表示、渲染与学习[J]．中国科学：信息科学, 2023, 53(10): 1858-1891)

[2] Zhang H W, Lin S Y, Shao R Z, *et al*. CloSET: modeling clothed humans on continuous surface with explicit template decomposition[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2023: 501-511

[3] Song D Y, Lee H, Seo J, *et al*. DIFu: depth-guided implicit function for clothed human reconstruction[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2023: 8738-8747

[4] Xiao J J, Zhang Q, Xu Z, *et al*. NECA: neural customizable human avatar[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2024: 20091-20101

[5] Qian Z Y, Wang S F, Mihajlovic M, *et al*. 3DGS-Avatar: animatable avatars via deformable 3D Gaussian splatting[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2024: 5020-5030

[6] Pu Juncheng, Liu Li, Fu Xiaodong, *et al*. Clothing visual representation for 3D human reconstruction[J]. Journal of Computer-Aided Design & Computer Graphics, 2022, 34(3): 352-363(in Chinese)

最新录用

(普骏程, 刘骊, 付晓东, 等. 三维人体重建中的服装视觉信息表示[J]. 计算机辅助设计与图形学学报, 2022, 34(3): 352-363)

[7] Weng C Y, Curless B, Srinivasan P P, *et al*. HumanNeRF: free-viewpoint rendering of moving people from monocular video[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2022: 16189-16199

[8] Peng S D, Zhang Y Q, Xu Y H, *et al*. Neural body: implicit neural representations with structured latent codes for novel view synthesis of dynamic humans[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2021: 9050-9059

[9] Loper M, Mahmood N, Romero J, *et al*. SMPL: a skinned multi-person linear model[J]. ACM Transactions on Graphics (TOG), 2015, 34(6): Article No.248

[10] Liu Y X, Li Z, Liu Y B, *et al*. TexVocab: texture vocabulary-conditioned human avatars[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2024: 1715-1725

[11] Wang S F, Schwarz K, Geiger A, *et al*. ARAH: animatable volume rendering of articulated human SDFs[C] //Proceedings of the 17th European Conference on Computer Vision. Heidelberg: Springer, 2022: 1-19

[12] Guo C, Jiang T J, Chen X, *et al*. Vid2Avatar: 3D avatar reconstruction from videos in the wild via self-supervised scene decomposition[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2023: 12858-12868

[13] Yu Z M, Cheng W, Liu X, *et al*. MonoHuman: animatable human neural field from monocular video[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2023: 16943-16953

[14] Xiang T G, Sun A, Wu J J, *et al*. Rendering humans from object-occluded monocular videos[C] //Proceedings of the IEEE/CVF International Conference on Computer Vision. Los Alamitos: IEEE Computer Society Press, 2023: 3216-3227

[15] Jiang B Y, Zhang Y D, Wei X K, *et al*. H4D: human 4D modeling by learning neural compositional representation[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2022: 19333-19343

[16] Ma Q L, Yang J L, Tang S Y, *et al*. The power of points for modeling humans in clothing[C] //Proceedings of the IEEE/CVF International Conference on Computer Vision. Los Alamitos: IEEE Computer Society Press, 2021: 10954-10964

[17] Ma Q L, Saito S, Yang J L, *et al*. SCALE: modeling clothed humans with a surface codec of articulated local elements[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2021: 16077-16088

[18] Zhao F, Li Z K, Huang S L, *et al*. Learning anchor transformations for 3D garment animation[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2023: 491-500

[19] Yoon J S, Ceylan D, Wang T Y, *et al*. Learning motion-dependent appearance for high-fidelity rendering of dynamic humans from a single camera[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2022: 3397-3407

[20] Mildenhall B, Srinivasan P P, Tancik M, *et al*. NeRF: representing scenes as neural radiance fields for view synthesis[J]. Communications of the ACM, 2021, 65(1): 99-106

[21] Jayasundara V, Agrawal A, Heron N, *et al*. FlexNeRF: photorealistic free-viewpoint rendering of moving humans from sparse views[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2023: 21118-21127

[22] Chen J C, Yi W T, Ma L Q, *et al*. GM-NeRF: learning generalizable model-based neural radiance fields from multi-view images[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2023: 20648-20658

[23] Pang H K, Zhu H M, Kortylewski A, *et al*. ASH: animatable Gaussian splats for efficient and photoreal human rendering[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2024: 1165-1175

[24] Liu X, Zhan X H, Tang J X, *et al*. HumanGaussian: text-driven 3D human generation with Gaussian splatting[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2024: 6646-6657

[25] Li C, Lin J H, Lee G H. GhuNeRF: generalizable human NeRF from a monocular video[C] //Proceedings of the International Conference on 3D Vision. Los Alamitos: IEEE Computer Society Press, 2024: 923-932

[26] Hu S K, Hong F Z, Pan L, *et al*. SHERF: generalizable human NeRF from a single image[C] //Proceedings of the IEEE/CVF International Conference on Computer Vision. Los Alamitos: IEEE Computer Society Press, 2023: 9318-9330

[27] He T, Xu Y L, Saito S, *et al*. ARCH++: animation-ready clothed human reconstruction revisited[C] //Proceedings of the IEEE/CVF International Conference on Computer Vision. Los Alamitos: IEEE Computer Society Press, 2021: 11026-11036

[28] Cao Y K, Han K, Wong K Y K. SeSDF: self-evolved signed distance field for implicit 3D clothed human reconstruction[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2023: 4647-4657

[29] Svitov D, Gudkov D, Bashirov R, *et al*. DINAR: diffusion inpainting of neural textures for one-shot human avatars[C] //Proceedings of the IEEE/CVF International Conference on Computer Vision. Los Alamitos: IEEE Computer Society Press, 2023: 7039-7049

[30] Xiu Y L, Yang J L, Cao X, *et al*. ECON: explicit clothed humans optimized via normal integration[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2023: 512-523

[31] Chen X L, Li W Y, Cohen-Or D, *et al*. MoCo-Flow: neural motion consensus flow for dynamic humans in stationary monocular cameras[J]. Computer Graphics Forum, 2022, 41(2): 147-161

录用稿